German Text Simplification With Generative Language Models – A Comparison Of Different LLMs

Tim Ostrolucký
Heinrich Heine Universität Düsseldorf
NiCE Cognigy
tim.ostrolucky@hhu.de

Abstract

This study investigates the capability of contemporary generative language models to simplify German-language texts. Models from leading providers – OpenAI, Anthropic, Meta, Mistral, Deepseek, and Google – were evaluated through a series of experiments. First, the outputs were compared using automatic text simplification metrics and illustrative examples. Subsequently, a human readability study was conducted, collecting judgments on the perceived complexity of the generated texts. The findings provide insights into the relative strengths and limitations of current large language models in producing German text simplifications.

1 Introduction

The daily confrontation with a multitude of texts is an essential part of everyday life. Be it searching for the latest news on the internet, reading an interesting book or dealing with scientific articles in the context of your own bachelor thesis. Some texts are easier to read than others. The target group for which the texts are written plays a major role. For example, texts for scientists and experts differ in writing style from texts for school children or people learning a new language, as the following example from Temnikova (2012) illustrates:

a) High-quality learning environments are a necessary precondition for facilitation and enhancement of the on-going learning process.

b) Children need good schools if they are to learn properly.

Both sentences have the same meaning, but sentence b) is much easier to understand.

At the lexical level, the use of "non-familiar words such as infrequent words, technical terminology and abstract concepts" (Temnikova, 2012) makes texts harder to read, while, on the syntactic level, long sentences and convoluted syntax lead to higher text complexity (Temnikova, 2012).

Due to the use of long, compound words and nested subordinate clauses, German has a reputation for being a complicated language. According to a study by the company Capito, only 8.4% of people in Austria understand texts written in language levels C1 and C2 (Capito, 2024). The LEO study by the University of Hamburg paints a similar picture: based on a sample of 7,192 randomly selected people living in Germany, the researchers found that 12.1% of respondents have difficulties with reading and writing, limiting them in some areas of daily life, e.g. online banking or reading news on politics or other complex topics in the newspapers (Grotlüschen et al., 2019).

The rise of generative language models such as ChatGPT (OpenAI et al., 2024), Google Gemini (Comanici et al., 2025) and others, which are playing an increasingly important role in our everyday lives, led to the question whether they could be used to simplify complicated texts so that they are easier to understand and, if so, which of these models is best suited to this task. The present study will address these questions.

2 Related Work

Text Simplification is the process of "modifying the content and structure of a [text] to improve its readability while retaining its original meaning" (Alva-Manchego et al., 2019). It is "promising technique to help people with various reading difficulties" (Arase and Wu, 2024) and non-native speakers. It can be done either manually or with the help of automatic tools.

Simplifying texts manually on a large scale can be costly and time-consuming. This is why a lot of research is being carried out in the field of automatic Text Simplification. Current research mainly

focuses on English and on the simplification of individual sentences as opposed to the simplification of whole texts (Stodden et al., 2023) but there is ongoing research in this area in other languages as well.

Since 2020, research is focusing on training or fine-tuning sequence-to-sequence models to simplify texts (Stodden, 2024b) and on generating simplifications using large language models, with the best LLMs achieving comparable results to dedicated state-of-the-art text simplification benchmarks, without any training on text simplification datasets, and showing a greater variability of simplification operations (Kew et al., 2023). In a study by Qiang et al. (2025), the simplifications generated by the LLMs even surpassed the quality of human reference simplifications in some cases.

The way in which queries are presented to the LLM also has a major impact on the quality of the responses received. Therefore, prompt engineering plays a very important role in research into text simplification using generative language models to maximize the quality of the results (Arase and Wu, 2024; Wu and Huang, 2023).

In this paper, the focus is on document-level simplification of German language newspaper texts to plain language, comparing the outputs of various generative models and using prompt engineering to maximize their performance.

3 Data & Resources

The following section describes the data set and the (software) resources used in the experiments.

3.1 DEPlain Corpus

The DEPlain corpus is a dataset for Text Simplification in German with "parallel, professionally written and manually aligned simplifications in plain German" (Stodden et al., 2023). It consists of 4 subcorpora – 2 at document level and 2 at sentence level – and contains texts from 2 domains: news and web. There is one simplification/reference for each original text (Stodden et al., 2023). Texts in Plain German ("Einfache Sprache") have reduced complexity and are intended for "people for whom the source texts are too hard to understand" (Maaß, 2020). According to Stodden et al. (2023), the main target group of these texts are people with reading problems as well as non-native German speakers. The corresponding CEFR levels are levels A2 and B1 (Stodden et al., 2023).

In this study, the document-level subcorpus of the news domain (DEPlain-APA) is used due to the high quality of the professional simplifications and the consistent language levels in source texts and simplifications – in contrast to the web part where the language levels vary. Although DEPlain also provides sentence-level data, the document-level subset was selected because it captures simplification beyond isolated sentence transformations. This setting allows for document-level operations such as sentence splitting, sentence merging, and the integration of explanatory information, which are relevant for producing coherent and accessible simplified texts. The chosen subcorpus consists of 483 document pairs of news and their respective professional simplifications published by the Austrian Press Agency (APA) between May 2019 and April 2021. The language level of the original texts in the news part of the DEPlain corpus is B1, that of the simplifications is A2 (Stodden et al., 2023).[1] According to Regina Stodden (personal communication, February 17, 2025), the simplifications were made by the company Capito from Graz, Austria.

3.2 EASSE-DE Evaluation Tool

The EASSE evaluation tool by Alva-Manchego et al. (2019) was designed to standardize and make sentence simplification easier to perform, with the acronym standing for "Easier Automatic Sentence Simplification Evaluation". The package contains a large collection of common evaluation metrics for Text Simplification in English. Furthermore, the EASSE package offers the option of generating an HTML report in which the evaluation results and examples of various transformations are presented in a clear form, also with the aid of diagrams. Finally, it contains some standard corpora for text simplification and the corresponding outputs of several text simplification systems (Alva-Manchego et al., 2019).

EASSE-DE (Stodden, 2024a) is the German equivalent and part of the EASSE-multi framework. It has the same functionalities as EASSE, but some adjustments have been made because "the way how English sentences are simplified differs from the German or Spanish ways" (Stodden, 2024a). The multilingual version addresses precisely those problems which arise when using the original EASSE

[1] For an example pair of (shortened) original text and simplification see Example 1 in the Appendix

tool for the evaluation of languages other than English.

3.3 Large Language Models

In this study, a wide variety of Large Language Models from different providers is considered: in addition to the models from some of the leading companies in the field of artificial intelligence, namely OpenAI, Anthropic, Meta and Google – all of which are US-based – also a LLM from the French company Mistral as a European alternative and Deepseek, a Chinese provider, are examinated.

The following 9 models were used:

- OpenAI: GPT-3.5 Turbo (Brown et al., 2020), GPT-4 & GPT-4o (OpenAI et al., 2024)
- Anthropic: Claude 3.5 Haiku & Claude 3.5 Sonnet (Anthropic, 2024)
- Meta Llama: Llama 3.1 405B (Grattafiori et al., 2024)
- Mistral AI: Mistral 7B (Jiang et al., 2023)
- Deepseek: Deepseek v3 (DeepSeek-AI et al., 2025)
- Google Gemini: Gemini 2.5 Flash (Comanici et al., 2025)

3.4 Cognigy.AI Platform

The Cognigy.AI platform, which is meant for constructing chat/voice bots with little or no code and which can be connected to a number of LLMs, was employed as a medium to query the answers from the language models, centralizing and facilitating the API requests to the models of the different providers. Figure 1 illustrates how it was used in the Prompt Engineering part of this study.

The company NiCE Cognigy also provided complimentary access to the language models used in this study.

4 Experiments & Results

The experiments carried out in this study consist of three parts: Prompt Engineering, Model Evaluation, and a Readability Survey.

The general procedure for the first two parts was the following: for every model/prompt template, the LLMs were queried – via API calls to the Cognigy.AI platform – to create simplifications of the individual news articles from the DEPlain corpus one-by-one, with the temperature parameter being set to 0.7 to allow some variability in the models' responses. The generated simplifications of the specific model/prompt template were stored in a

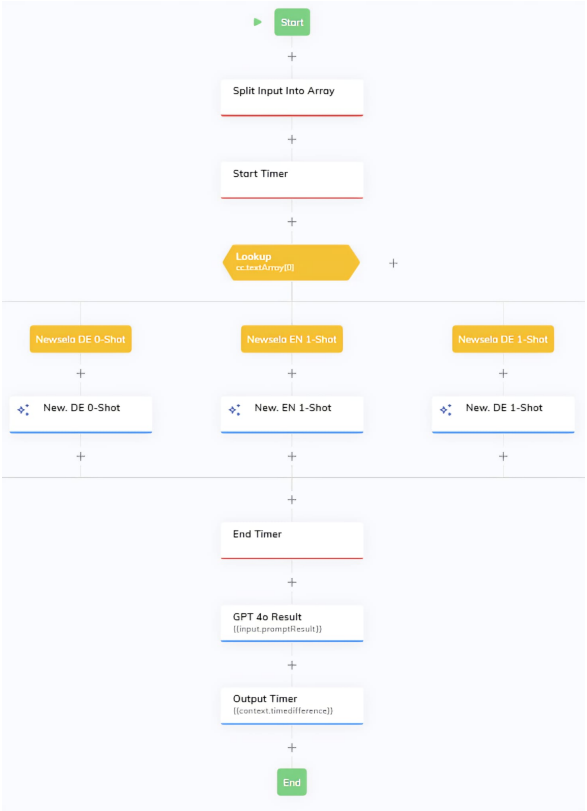


Figure 1: Screenshot of the "Prompt Engineering" Flow, detail

text file. In another file, the response times of the language model were recorded to check how long it takes the LLM to generate a response on average. In case of an error, e.g. a timeout from the LLM, the string "ERROR" was written to both files.[2] After processing the whole dataset, the outputs were evaluated using the EASSE-DE package.

To evaluate the different aspects of the language models' simplifications, some of the most widespread metrics were used (Alva-Manchego et al., 2021; Tanprasert and Kauchak, 2021), namely BLEU (Papineni et al., 2002) for meaning preservation, SARI (Xu et al., 2016) and BERTScore (Zhang et al., 2020) for quality assessment, and Flesch Reading Ease (Flesch, 1948) – specifically the German adaptation by Amstad (1978) – and the first Wiener Sachtextformel (Bamberger and Vanecek, 1984) for readability. Additionally, statistics like compression ratio, sentence splits, average sentence length (in words) and average word length (in syllables) were employed to get further insights.

[2] In the Model Evaluation, the original text was written into the text file with the simplifications if an error occurred, as it was deemed to distort the metrics less. However, the Prompt Engineering experiment was not re-run with this setting since it would have been too time consuming.

Learned text simplification metrics such as LENS (Maddela et al., 2023) and DETECT (Korobeynikova et al., 2026), which are trained to predict human judgments of simplification quality, are not reported. These metrics have been developed and validated primarily for sentence-level simplification. However, the present work focuses on document-level simplification, where phenomena such as sentence splitting, sentence merging, and the insertion of explanatory content may occur. Therefore, these metrics cannot be directly applied without an additional alignment procedure.

4.1 Prompt Engineering

This experiment was aimed at finding out which prompt is best suited to simplify texts (from the DEPlain data set). As a basis served the study by Arase and Wu (2024) in which the researchers found out that LLMs achieved the best results when the prompts were tailored to the characteristics of individual datasets, such as target audience or simplification operations. To test this hypothesis, a very similar experimental design to that of Arase and Wu (2024) was used: 5 different prompt formulations were tested, varying the language in which the prompt is written – English or German – and the number of examples – 0, 1 or 3. This yields a total of 30 different prompts.

As prompt templates, the best prompts from Arase and Wu (2024) for the TURK (Xu et al., 2016), ASSET (Alva-Manchego et al., 2020) and Newsela (Xu et al., 2015) corpus were used in this experiment. In addition, the best performing prompt from the study by Wu and Huang (2023) and a prompt which was specifically tailored to the requirements of the DEPlain corpus, following some common best practices for prompt formulation and formatting, and simplification rules published on the website of Capito and in the rulebook on plain language by Maaß (2015), were considered.[3] The tailored prompt will be called Capito in the following.

Prompt engineering was performed exclusively with GPT-4o, as performing prompt engineering for all large language models considered would be outside the scope of this study.

4.1.1 Analysis

Before comparing the prompts individually, they were first grouped by prompt template, language, and number of examples, computing the average scores for each group, to get some first impressions on the quality of the produced simplifications. You can find detailed results in Table 5 in the Appendix.

The individual prompts are examined below. In Figure 2 in the Appendix, the prompts are sorted according to the "OVERALL RANK".

To find out which prompt performed best in terms of the evaluation metrics, the table with the results from the EASSE reports was sorted by the different metrics and each prompt (and also the baselines) was assigned a rank for each of these metrics, from 1 for the best to 33 for the worst. In the end, the ranks of all the automatic metrics (BLEU, SARI, BERTScore-Precision, Flesch Reading Ease, Wiener Sachtextformel 1) were summed up to get the OVERALL RANK. The lowest value for OVERALL RANK and therefore the best result was achieved by **capito_de_3**; from a metrics perspective, only the Reference Baseline was better. The prompt achieved the best values for SARI and BERTScore-Precision, and was also always among the top five for the other metrics. In terms of average sentence length, the simplifications generated by capito_de_3 fall even below the references, and in terms of sentence splits and average word length, the prompt is on the same level as the best in the respective statistics. It was only in terms of compression ratio and response time that it was not among the best. The error rate is also very low at 1.25%. The remaining Capito prompts follow in 2nd to 6th place, confirming Arase and Wu's (2024) finding that prompts tailored to the texts to be simplified produce the best results. Moreover, it can be seen that prompts with more examples and prompts in German perform better.

4.2 Model Evaluation

After having found out which prompt yields the best results, the focus of this chapter is comparing the quality of simplifications produced by different generative language models. Originally, the capito_de_3 prompt was intended to be used for comparing the diffent models. However, not all LLMs could cope with the combination of a long prompt and relatively long input text. Therefore, the simplifications were generated using the **capito_de_1** prompt instead. It was second-best in the previous evaluation and provided comparable values to the best prompt for all metrics and statistics.

[3] For the Prompt Templates see Table 3 and Table 4 in the Appendix

Model	BLEU ↑	SARI ↑	BS-P ↑	FRE ↑	WSTF1 ↓	Comp. Ratio ↓	Sentence Splits ↑	Avg. sent. length ↓	Avg. word length ↓	Avg. time ↓	OVR ↓
ChatGPT-4o	**22.62**$_{(3)}$	**43.42**$_{(2)}$	**0.53**$_{(3)}$	**65.71**$_{(2)}$	**6.59**$_{(2)}$	0.81	**0.98**	**9.13**	1.77	5.89	**12**
Claude 3.5 Sonnet	15.98$_{(6)}$	41.12$_{(4)}$	0.46$_{(6)}$	61.36$_{(5)}$	7.42$_{(5)}$	0.71	0.68	11.93	1.78	7.13	26
Llama 3.1 405B	19.59$_{(5)}$	41.24$_{(3)}$	0.48$_{(5)}$	61.24$_{(7)}$	7.47$_{(8)}$	0.76	0.76	11.01	1.79	9.18	28
Mistral 7B Instruct	20.29$_{(4)}$	41.08$_{(5)}$	0.49$_{(4)}$	61.18$_{(8)}$	7.46$_{(7)}$	0.77	0.75	11.45	1.79	10.18	28
ChatGPT-4	9.91$_{(8)}$	39.04$_{(7)}$	0.39$_{(8)}$	62.17$_{(4)}$	7.22$_{(4)}$	0.55	0.49	12.99	1.75	6.42	31
ChatGPT-3.5 Turbo	8.17$_{(9)}$	35.38$_{(9)}$	0.32$_{(10)}$	65.39$_{(3)}$	6.69$_{(3)}$	0.64	0.78	10.47	**1.70**	6.40	34
Claude 3.5 Haiku	15.70$_{(7)}$	40.62$_{(6)}$	0.46$_{(7)}$	60.87$_{(9)}$	7.56$_{(9)}$	0.70	0.68	11.51	1.79	7.87	38
Gemini 2.5 Flash	6.87$_{(10)}$	36.88$_{(8)}$	0.33$_{(9)}$	57.33$_{(10)}$	8.24$_{(10)}$	0.46	0.36	14.34	1.83	8.72	47
Deepseek v3	3.19$_{(11)}$	33.23$_{(10)}$	0.28$_{(11)}$	56.65$_{(11)}$	8.53$_{(11)}$	**0.42**	0.38	13.34	1.84	**5.66**	54
Open Source Avg.	**14.36**	38.52	0.42	59.69	7.82	0.65	0.63	11.93	1.81	n/a	n/a
Closed Source Avg.	13.21	**39.41**	0.42	**62.14**	**7.29**	0.65	**0.65**	**11.73**	**1.77**	n/a	n/a
Original	33.84$_{(2)}$	17.50$_{(11)}$	0.57$_{(2)}$	61.24$_{(6)}$	7.43$_{(6)}$	1.00	1.00	10.79	1.83	n/a	27
Reference	100.00$_{(1)}$	100.00$_{(1)}$	1.00$_{(1)}$	66.55$_{(1)}$	6.39$_{(1)}$	0.91	1.06	9.65	1.76	n/a	5

Table 1: Scores of the automatic metrics and text statistics for the individual models, ranked by OVERALL RANK (OVR); $_{(subscript)}$ indicates the rank of the models in the indidual metrics which are summed up to OVERALL RANK; the different models are color-coded (Closed Source = red, Open Source/"Openly Available" = green); the best values for each group are written in **bold**; averages for open and closed source models, and baselines for comparison

4.2.1 Quantitative Analysis

Before proceeding with the analysis, it is worth noting that Mistral 7B Instruct (7.08%) and Llama 3.1 405B (5.42%) had error rates of more than 5%, which may have distorted the metrics and statistics somewhat more than for the other models. The fact that, in the event of an error, the original text is written to the file with the simplifications, results in better values for similarity-based metrics such as BLEU, but also leads to poorer values for readability metrics, assuming that shorter words and sentences are used in the simplifications than in the source texts.

Combining the values of the five automatic metrics, BLEU, SARI, BERTScore, Flesch Reading Ease, and the Wiener Sachtextformel, to obtain the OVERALL RANK, GPT-4o performs best with a value of 12, surpassed only by the human reference simplifications. Claude 3.5 Sonnet ranks second among LLMs with a score of 26, just ahead of the source texts. Llama 3.1 405B and Mistral 7B each score 28, sharing first place among open source models. Deepseek v3 achieves the worst result with a score of 54. Overall, GPT-4o performs best among all LLMs on all 5 metrics and also achieves scores that are among the best in the text statistics, except for the compression ratio.

GPT-4o performs better overall than its predecessors GPT-3.5 Turbo and GPT-4. If we compare the two Claude LLMs 3.5 Haiku and 3.5 Sonnet, which represent the same model, only in different sizes, even if no exact details on the number of parameters are given, we see that both variants basically deliver comparable (in some cases even identical) results in most criteria, although – with the exception of Compression Ratio and Sentence Length – Claude 3.5 Sonnet always performs slightly better. The difference is only greater in the readability metrics and sentence length. In this case, the influence of the model size is not too strong, but it must be weighed up on a case-by-case basis whether the cost savings from using a smaller model may compensate for a possibly weaker quality of the results. It can be also said open and closed source models basically achieve similar results, even if closed source models perform slightly better.

For detailed results see Table 1.

4.2.2 Qualitative Analysis

In order to gain a more in-depth understanding of how the language models have simplified the newspaper articles, the focus of the analysis will now shift to the qualitative aspects of the simplifications. Due to the large amount of system outputs, only the most interesting observations will be described in this section with the help of some illustrative examples.

When it comes to the format of the LLM responses, some anomalies can be observed. One of these is that English texts are produced instead of German texts to varying degrees. However, this does not occur at all in two-thirds of the models examined, and in Claude 3.5 Haiku it occurs in only four simplifications. This problem is much more pronounced in Deepseek v3 and GPT-3.5 Turbo. 106 simplifications, or 22.08%, from Deepseek v3

are in English; in GPT-3.5 Turbo, 261, or 54.38%, are in the wrong language, which is more than half of all simplifications. This not only distorts the results of the metrics but also leads to texts that are incomprehensible for the intended audience and therefore unusable. A very good example of this distortion is GPT-3.5 Turbo: in the metrics that compare the generated simplifications with the references (and, in addition, with the source texts), it ranks at the bottom, but in the readability metrics, it ranks at the top. Language-specific features, such as shorter sentence and word lengths in English, serve as an explanation for the good readability scores and the short average word length of the generated simplifications, while the absence of n-grams from the references in the simplifications explains the low values in the other metrics. A possible explanation for that could be the composition of their training data. Both models were trained on corpora based on the Common Crawl dataset (Raffel et al., 2020); 93% of the data on which GPT-3 was trained is in English (Brown et al., 2020). Consequently, only the remaining 7% is in many other languages, one of which is German. The LLMs are therefore much more familiar with English, which could explain why so many texts were incorrectly generated in English.

Almost all LLMs, with the exception of GPT-3.5 Turbo and GPT-4o, have in common that they occasionally give a hint before the start of the actual simplification that the following text is a simplification. This note can be written in either German or English, in the case of English followed by a German or English text. For Claude 3.5 Haiku, this note is given in seven cases and therefore most frequently, for the other models it is provided only once. This peculiarity can be slightly detrimental to the scores of the similarity-based metrics, as these n-grams do not appear in the reference simplifications.

Example 1

ChatGPT-4: "Hier ist eine vereinfachte Version des Originaltextes: [...]"

Claude 3.5 Haiku: "Here is the simplified text: Wichtige Nachrichten zur Corona-Krise in einfacher Sprache. [...]"

Deepseek v3: "Here is a simplified version of the original text: Simple news overview: This special edition focuses on the coronavirus crisis [...]"

With regard to the content of the simplifications, most models summarize what they consider to be the most important information from several sentences in one longer sentence, which means that the simplifications of all LLMs, with the exception of GPT-4o and GPT-3.5 Turbo, use longer sentences on average than in the original messages. Gemini 2.5 Flash and Deepseek v3 show this behavior most frequently, which is reflected in the highest average sentence lengths.

Example 2

Original: "[...] Während der Corona-Krise haben die Österreicher mehr Nudeln aus Italien gegessen . [...] Das half auch der italienischen Lebensmittel-Industrie . [...]" (**2 sentences**)

Gemini 2.5 Flash: "[...] Außerdem aßen die Österreicher während der Krise mehr italienische Nudeln , was der italienischen Lebensmittelindustrie zugutekam ." (**1 sentence**)

During this simplification process, it can occasionally happen that the text is shortened too much, leaving out some information that is also important for understanding the text. This in turn leads to (extremely) low values for BLEU and also poor results for SARI and BERTScore-Precision. Deepseek v3 and Gemini 2.5 Flash, but also GPT-3.5 Turbo and GPT-4, are the models that retain the least of the original meaning of the texts or are the least similar to the given references. This is also consistent with the fact that these LLMs compress the source texts the most.

Example 3

Original: "[...] Sachertorte ist Österreichs beliebteste Mehlspeise auf Instagram . Wien Die Sachertorte ist die beliebteste Mehlspeise aus Österreich auf der Foto-Webseite Instagram . Mehr als 230.000 Fotos gibt es dort zur Sachertorte . Dabei wird das deutsche Wort " Sachertorte " in 8 verschiedenen Sprachen gleich verwendet . So wird " Sachertorte " auch auf Englisch und Italienisch verwendet . Auf Platz 2 der beliebtesten Mehlspeisen aus Österreich auf Instagram ist der Apfelstrudel . Platz 3 belegt der Kaiserschmarrn . Der Kaiserschmarrn wurde zum ersten Mal im Jahr 1854 für Kaiserin Elisabeth zubereitet . Auf Platz 4 und 5 liegen der Krapfen und der Gugelhupf . Der erste Knödel unter den Mehlspeisen landet auf Platz 10. Es ist der Germknödel . Der Marillenknödel ist auf Platz 14."

Gemini 2.5 Flash: "[...] Die Sachertorte ist die beliebteste österreichische Mehlspeise auf Instagram mit über 230.000 Fotos . Auf den nächsten Plätzen folgen Apfelstrudel , Kaiserschmarrn , Krapfen und Gugelhupf . Der Germknödel ist die beliebteste Knödelspeise auf Platz 10."

In Example 3, some questions remain unanswered resp. some information is lost, for example: 1) What is Instagram? 2) Sachertorte is called

that way in several languages. 3) Kaiserschmarrn was first prepared for Empress Sissi. 4) Apricot dumplings are not mentioned at all.

The Gemini output in Example 2 shows another phenomenon, namely that the LLMs occasionally use more complicated words than the original texts, as in this case “zugutekommen” instead of “helfen”. While this does not necessarily translate into lower scores in the readability metrics, as more complicated words do not have to be longer than simpler synonyms, it still has a big impact on the comprehensibility of texts.

However, it may well be the case that the more complicated words can be longer; Gemini 2.5 Flash uses the longest words on average, which negatively affects the readability scores. But not only complicated words can be longer than those in the source texts, as the following example illustrates:

Example 4

Original: "[...] Laut einer Studie wird **auf der Welt** immer mehr **Alkohol getrunken** . [...]"

Gemini 2.5 Flash: "[...] Der **weltweite Alkoholkonsum** nimmt zu . [...]"

A problem specific to Mistral 7B Instruct was that the generated texts are not always 100% grammatical; for instance, sometimes unsuitable words or incorrect prepositions are used – which again could be explained with a low proportion of German language data in the training set. An example of this is the following sentence: *"[...] US-Präsident Trump hat neue Bestrafungen gegen den Iran eingeführt . [...]"* The word “Bestrafung” exists in German, but it is not very common. The word “Strafe” is much more commonly used and would be more appropriate in this sentence. The following sentence also reads strangely to a native German speaker: *"Sechs Schüler werden aus einer Wiener Schule ausgeschlossen . [...]"* The correct wording would be "von einer Wiener Schule ausgeschlossen” because “aus” in this context implies a spatial dimension, in the sense of “the school building has been locked and the six pupils can no longer enter”, rather than the actual meaning that they have been expelled from the school.

Finally, Example 2 and Example 3 in the Appendix show simplifications generated by the two best models in terms of automatic metrics – GPT-4o and Claude 3.5 Sonnet. They sometimes even use a simpler vocabulary and sentence structure than in the human reference simplifications by Capito employees.

4.3 Human Evaluation: Readability Survey

Following the evaluation of the generative models with automatic metrics and selected examples, a readability study was conducted among students of the Heinrich Heine University Düsseldorf and the employees of NiCE Cognigy to verify the previous findings as human evaluation is viewed as the most reliable method for evaluating the quality of simplified texts (Štajner et al., 2016). In such surveys, it is common practice to show respondents both the original sentences and the simplifications and ask them to rate the following aspects on a scale between 1 and 3, or more often on a scale between 1 and 5: grammaticality, meaning preservation and simplicity (Štajner et al., 2016).

However, this study takes a slightly different approach. 9 texts were randomly selected for which none of the LLMs returned an error message in the previous experiment. Since these texts are relatively long and consist of several, usually 3 to 5 individual news, always one of those news items was selected for each of the 9 texts, and included in this survey. For each of these news texts, the respondents are shown 6 different variants: one of them is always the original text, one is the reference simplification from the DEPlain corpus and the remaining 4 are the outputs of 4 randomly selected LLMs. The outputs of each of the 9 language models considered in the previous experiment occur 4 times in this survey. The participants are asked to indicate how easy the text is to read on a scale of 1 to 5; texts with a value of 1 are the most difficult to read, texts with a value of 5 the easiest. As in most surveys of this type, it was not specified how “simplicity” is defined, but rather relied on the respondents’ perceptions of the term (Alva-Manchego et al., 2021). However, they were given one example of a level 1 text and one example of a level 5 text.[4] The other aspects are not considered. The participants do not know which of the variants is the original, which is the reference simplification and which are the versions of the LLMs. In addition, the introduction describing the procedure to the respondents states that all texts are exclusively the outputs of generative language models. This is to ensure the objectivity of the test subjects so that they treat all texts equally and focus exclusively on evaluating the readability of the texts. If the participants knew which of the texts were written by humans, they might be tempted to prioritize them.

[4] For the example sentences see Example 4 in the Appendix

Model	Avg. Score ↑
Gemini 2.5 Flash	4.54
ChatGPT-4	4.40
Deepseek v3	4.10
Llama 3.1 405B	4.10
ChatGPT-3.5 Turbo	4.03
ChatGPT-4o	3.84
Mistral 7B Instruct	3.74
Claude 3.5 Haiku	3.60
Claude 3.5 Sonnet	3.54
Reference	3.31
Original	3.12

Table 2: Average readability score in the human evaluation, overall

Therefore, the decision was made to take this approach to avoid bias. The fact that it is not stated which of the variants is the original text, however, also means that the aspect of meaning retention cannot be assessed. In order not to discourage potential participants by asking too many questions, the question on grammaticality was also left out, concentrating only on the readability aspect.

4.3.1 Evaluation

A total of 25 people took part in this study, 15 of whom were native speakers of German (60% of the participants), 8 were proficient in German at C1/C2 level (32%) and 2 at B1/B2 level (8%), i.e. approximately or slightly above the intended level of difficulty of the texts. There were no participants who spoke German at A1/A2 level. The answers of these respondents will be examined in more detail below to find out whether the findings from the previous section can be confirmed or whether human preferences differ from the results of automatic metrics.

And indeed: if you look at the average values of the readability ratings by the study participants (Table 2), you see a different picture. Simplifications generated by the Gemini 2.5 Flash model achieved the best score of 4.54 out of 5, followed by GPT-4 with 4.40, and Deepseek v3 and Llama 3.1 405B with 4.10 each as the best open source models. In terms of automatic metrics, these LLMs were at the bottom or in the middle of the field. GPT-4o, which in turn excelled in the model comparison and achieved top scores among the models in all metrics, came here in sixth place with a score of 3.84. According to the respondents, the Claude language models from Anthropic came last among the LLMs. However, even the simplifications of Claude 3.5 Sonnet, the worst model, are easier to read with a score of 3.54 than the references (3.31) and the original texts (3.12).

If you calculate the values for the different subgroups that participated in the survey individually (Table 6 – 8 in the Appendix), i.e. for native speakers and for people who speak German at B1/B2 level resp. C1/C2 level, you gain further insights.

What all target groups have in common is that they find source texts the most difficult to read, followed by the reference simplifications, so according to them all machine-generated simplifications are an improvement over source AND reference. In addition, the original and reference texts, as well as the majority of texts from the LLMs, tend to be easier to understand for respondents with a higher language proficiency, as would be expected. In a few cases, the model scores of C1/C2 learners are slightly higher than those of native speakers. Claude 3.5 Sonnet is the exception, as the highest score is given by participants with B1/B2 level.

A comparison with the values of the LLMs from the model comparison in Table 1 suggests that speakers with a high level of language competence, i.e. native speakers and speakers at C1/C2 level, prefer the compact presentation of the most important information, i.e. the output of the models that tend to compress the texts more.

For people with an intermediate language level, the models that achieved good results in the model comparison performed better in comparison, which could indicate that this target group places greater value on simpler formulations and explanations, although the compactness of the information presentation also plays a role here. These conclusions were drawn on the basis of two participants and should therefore be viewed with caution.

In summary, it can be said that the Gemini 2.5 Flash and the GPT-4 model emerged as the most suitable LLMs for text simplification in the readability study based on the ratings provided by the respondents, which somewhat relativizes the results of the model comparison using the automatic metrics. There, the shortening of information was seen as something negative, but the study participants responded positively and tended to give higher scores to shorter texts. It should be noted that the correctness of the content of the machine-generated texts was not checked manually in detail, which is why the results should be taken with a pinch of salt. Further results of the survey can be found in Appendix F.

Metric	Kendall's τ_b	Kendall's p-value	Spearman's ρ	Spearman's p-value
BLEU	-0.550*	0.019	-0.738**	0.010
SARI	-0.183	0.435	-0.196	0.564
BERTScore-Precision	-0.500*	0.035	-0.699*	0.017
Flesch Reading Ease	-0.241	0.309	-0.322	0.334
Wiener Sachtextformel 1	0.294	0.212	0.387	0.239
Compression Ratio	-0.624**	0.008	-0.774**	0.005
Sentence Splits	-0.500*	0.035	-0.685*	0.020
Avg. Sentence Length	0.367	0.118	0.542	0.085
Avg. Word Length	0.038	0.874	0.055	0.872

Table 3: System-level correlation of human rating with automatic metrics and structural text features ($N = 11$). Significance levels: * : $p \leq 0.05$, ** : $p \leq 0.01$.

4.3.2 Correlation with Automatic Metrics

Additionally, a system-level correlation analysis was conducted to investigate the association between automatic metrics, structural text features, and the overall human readability ratings. To quantify the association between human ratings and the evaluated metrics, Kendall's (1948) and Spearman's (1904) correlation coefficients were computed together with their corresponding p-values.

Similar trends can be observed for both correlation coefficients. Interestingly, the automatic metrics do not follow the anticipated direction: BLEU, SARI, BERTScore-Precision, and Flesch Reading Ease show negative correlations with human readability ratings, whereas the Wiener Sachtextformel 1 shows a positive correlation. For BLEU and BERTScore, these correlations are statistically significant, indicating that texts with less similarity to the original text tended to receive higher readability ratings from the contestants.

Among the text features, the compression ratio and sentence splits are particularly interesting, as their correlations with readability ratings are statistically significant. The finding that texts with lower compression ratios (i.e. stronger compression) and fewer sentences than the original text tend to receive higher perceived readability ratings supports the pattern observed in the readability survey evaluation. Although the Spearman correlation narrowly misses the statistical significance threshold, there is an indication that respondents rated texts with longer average sentences as more readable. This could be related to the fact that longer sentences often resulted from combining information that was distributed across multiple sentences in the original text, allowing the generated texts to present the same content in a more compact form.

Overall, within the considered sample of respondents, structural text features showed the strongest associations with human readability ratings. While some automatic metrics also exhibited significant correlations, these relationships followed the opposite direction than expected, suggesting that readability is influenced more by how information is structured and condensed than by the degree of similarity to the original text.

5 Summary

This study provides an overview of how good different LLMs are at simplifying German-language texts by performing different experiments.

First, Prompt Engineering revealed the following findings: 1) Prompts specifically adapted to the texts to be simplified, the target group (including language) and the simplification operations to be carried out yielded the best results. 2) Few-shot prompting improves the quality of responses. 3) Prompt format and clear, structured instructions play a major role in achieving the desired results.

In the Model Evaluation, ChatGPT-4o produced the best results according to automatic text simplification metrics, which was also supported by illustrative examples. Open and closed source models achieved comparable results on average, with closed source models performing only slightly better. GPT-4o outperformed its predecessors GPT-3.5 Turbo and GPT-4, while model size did not significantly affect the Claude 3.5 models.

Finally, the Readability Survey found out that participants with advanced and native German language skills seem to prefer texts that summarize the most important information in a compact way, while for speakers with intermediate language skills, the simplicity of the wording and sentence structure seems to play a greater role for their comprehension. This is in line with the correlation analysis, which suggests that perceived readability is primarily related to how information is structured and condensed rather than to the preservation of the original text.

Limitations & Open Issues

The automatic evaluation metrics are not perfect and human evaluation is preferable (Alva-Manchego et al., 2021). However, they were used in this study nevertheless, as they are the most widely used in text simplification research (Alva-Manchego et al., 2021; Tanprasert and Kauchak, 2021). In addition, a purely human evaluation would not be practicable due to the large quantity and the associated very high time expenditure, nor would it be objectively quantifiable. Alva-Manchego et al. (2021), Sulem et al. (2018) and Tanprasert and Kauchak (2021) investigated the shortcomings of the metrics in detail.

In the present paper, all the texts used in the experiments are from the news domain. In further studies, one could take a more diverse corpus that includes other topic areas (or include other corpora in the experiments in addition to DEPlain) and compare how well the different models perform in the different domains, whether there is a topic area in which one model performs particularly well and shed light on other similar questions.

Prompt Engineering was exclusively carried out for GPT-4o. It is acknowledged that each generative language model may have different preferences regarding prompts and that a prompt that works best with GPT-4o may not necessarily lead to optimal results with other LLMs. As a result, a slight bias in favor of GPT-4o may be present in the model comparison. However, it was not possible to proceed otherwise in this study, as it would be outside of its scope. Performing Prompt Engineering for the other models as well remains an interesting question for further research.

The field of Text Simplification continues to be a relevant and interesting area of research in which there is still much to explore with the emergence of new Large Language Models, as well as new metrics and corpora, and the study of languages that have been less researched in this area so far. Gaining a better understanding of how exactly the LLMs arrive at the answers also plays an important role here, because up to now they have been a kind of "black box", and it is not entirely clear what happens inside and it is difficult to find reasons for occasional undesired behavior. Research into the internal processes within the models, such as that conducted by the scientists at Anthropic (2025), could help with this and contribute to achieving better results in Text Simplification and other tasks.

Lay Summary

Some texts are difficult to understand because they use complex words, long sentences or contain a lot of details. Simplifying texts can help people to understand the texts more easily. This is very important for people who have problems with reading or people who are learning a language. Good simplifications do not only replace complex words with easier words. Good simplifications also shorten sentences, explain difficult words and can summarize the most important information.

Large Language Models (LLMs) are computer programs that can write texts like humans. ChatGPT is one example of a LLM. Other companies, like Google, also made such models. These models can do a lot of things, for example simplify texts. However, models from different companies can generate different results. There are mathematical formulas which tell how good a simplification is. But it is not clear how well these formulas match with what humans find easy to read.

This study asked how well different models can simplify German texts. It also looked at how the models made the texts easier to read. The study compared different instructions to see which helps the models to create the simplest texts. Finally, it checked whether the mathematical formulas agree with what people think.

The study tested 9 different models. The models had to simplify around 500 German news articles. The results were compared with a human simplification. Precise instructions adapted to the original texts that told the model exactly what to do gave the best results. It also helped to give the models examples of what they should do. ChatGPT-4o was the best model according to the formulas.

25 people were asked to say how easy to read they find the texts by the models. The survey showed that different readers find different things more important. People who are good at German like shorter texts more. People who are learning German also like short texts but they also like easier words and shorter sentences.

Asking more people how easy to read they find the texts can give more precise results. Comparing texts from topics other than news, for example medical or legal texts, could also be an interesting idea for further research. To summarize, simplifying texts with Large Language Models can help make texts easier to understand for a bigger group of people.

Acknowledgments

The author would like to thank the company NiCE Cognigy for kindly supporting this study, and the students of Heinrich Heine University Düsseldorf and the employees of NiCE Cognigy who participated in the readability survey. Special thanks go to Regina Stodden from the University of Bielefeld for assisting with questions about the DEPlain corpus and the EASSE-DE evaluation tool, as well as for providing literature recommendations on the topic of Text Simplification. Finally, sincere thanks to the Department of Computational Linguistics at Heinrich Heine Universität Düsseldorf for its support, especially to Laura Kallmeyer and Kilian Evang.

References

Fernando Alva-Manchego, Louis Martin, Antoine Bordes, Carolina Scarton, Benoît Sagot, and Lucia Specia. 2020. ASSET: A Dataset for Tuning and Evaluation of Sentence Simplification Models with Multiple Rewriting Transformations. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 4668–4679, Online. Association for Computational Linguistics.

Fernando Alva-Manchego, Louis Martin, Carolina Scarton, and Lucia Specia. 2019. EASSE: Easier Automatic Sentence Simplification Evaluation. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP): System Demonstrations*, pages 49–54, Hong Kong, China. Association for Computational Linguistics.

Fernando Alva-Manchego, Carolina Scarton, and Lucia Specia. 2021. The (Un)Suitability of Automatic Evaluation Metrics for Text Simplification. *Computational Linguistics*, 47(4):861–889.

Toni Amstad. 1978. *Wie verständlich sind unsere Zeitungen?* PhD Thesis, Studenten-Schreib-Service, Zürich.

Anthropic. 2024. The Claude 3 Model Family: Opus, Sonnet, Haiku. Model card.

Anthropic. 2025. Tracing the Thoughts of a Large Language Model. Accessed: 2026-04-03.

Yuki Arase and Xuanxin Wu. 2024. Evaluation of ChatGPT Models on Sentence Simplification. Association for Natural Language Processing.

Richard Bamberger and Erich Vanecek. 1984. *Lesen-Verstehen-Lernen-Schreiben: Die Schwierigkeitsstufen von Texten in deutscher Sprache*. Jugend u. Volk Sauerlaender.

Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel M. Ziegler, Jeffrey Wu, Clemens Winter, and 12 others. 2020. Language models are few-shot learners. *Preprint*, arXiv:2005.14165.

Capito. 2024. 6 Schritte, für bessere Texte in der passenden Sprachstufe. Retrieved February 21, 2025.

Gheorghe Comanici, Eric Bieber, Mike Schaekermann, Ice Pasupat, Noveen Sachdeva, Inderjit Dhillon, Marcel Blistein, Ori Ram, Dan Zhang, Evan Rosen, Luke Marris, Sam Petulla, Colin Gaffney, Asaf Aharoni, Nathan Lintz, Tiago Cardal Pais, Henrik Jacobsson, Idan Szpektor, Nan-Jiang Jiang, and 3416 others. 2025. Gemini 2.5: Pushing the Frontier with Advanced Reasoning, Multimodality, Long Context, and Next Generation Agentic Capabilities. *Preprint*, arXiv:2507.06261.

DeepSeek-AI, Aixin Liu, Bei Feng, Bing Xue, Bingxuan Wang, Bochao Wu, Chengda Lu, Chenggang Zhao, Chengqi Deng, Chenyu Zhang, Chong Ruan, Damai Dai, Daya Guo, Dejian Yang, Deli Chen, Dongjie Ji, Erhang Li, Fangyun Lin, Fucong Dai, and 181 others. 2025. DeepSeek-V3 Technical Report. *Preprint*, arXiv:2412.19437.

Rudolph Flesch. 1948. A New Readability Yardstick. *Journal of Applied Psychology*, 32(3):221–233.

Aaron Grattafiori, Abhimanyu Dubey, Abhinav Jauhri, Abhinav Pandey, Abhishek Kadian, Ahmad Al-Dahle, Aiesha Letman, Akhil Mathur, Alan Schelten, Alex Vaughan, Amy Yang, Angela Fan, Anirudh Goyal, Anthony Hartshorn, Aobo Yang, Archi Mitra, Archie Sravankumar, Artem Korenev, Arthur Hinsvark, and 542 others. 2024. The Llama 3 Herd of Models. *Preprint*, arXiv:2407.21783.

Anke Grotlüschen, Klaus Buddeberg, Gregor Dutz, Lisanne Heilmann, and Christopher Stammer. 2019. LEO – Leben mit geringer Literalität. Pressebroschüre. https://leo.blogs.uni-hamburg.de/wp-content/uploads/2022/09/LEO2018-Presseheft.pdf. Retrieved May 21, 2025.

Albert Q. Jiang, Alexandre Sablayrolles, Arthur Mensch, Chris Bamford, Devendra Singh Chaplot, Diego de las Casas, Florian Bressand, Gianna Lengyel, Guillaume Lample, Lucile Saulnier, Lélio Renard Lavaud, Marie-Anne Lachaux, Pierre Stock, Teven Le Scao, Thibaut Lavril, Thomas Wang, Timothée Lacroix, and William El Sayed. 2023. Mistral 7B. *Preprint*, arXiv:2310.06825.

Maurice George Kendall. 1948. *Rank Correlation Methods*. Charles Griffin & Co., London.

Tannon Kew, Alison Chi, Laura Vásquez-Rodríguez, Sweta Agrawal, Dennis Aumiller, Fernando Alva-Manchego, and Matthew Shardlow. 2023. BLESS: Benchmarking Large Language Models on Sentence Simplification. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 13291–13309, Singapore. Association for Computational Linguistics.

Maria Korobeynikova, Alessia Battisti, Lukas Fischer, and Yingqiang Gao. 2026. DETECT: Determining Ease and Textual Clarity of German Text Simplifications. In *Proceedings of the 19th Conference of the European Chapter of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 2852–2882, Rabat, Morocco. Association for Computational Linguistics.

Christiane Maaß. 2015. *Leichte Sprache – Das Regelbuch*, volume 1. LIT.

Christiane Maaß. 2020. Easy Language – Plain Language – Easy Language Plus: Balancing Comprehensibility and Acceptability. In *Easy – Plain – Accessible*, volume 3 of *Easy – Plain – Accessible*. Frank & Timme – Verlag für wissenschaftliche Literatur.

Mounica Maddela, Yao Dou, David Heineman, and Wei Xu. 2023. LENS: A Learnable Evaluation Metric for Text Simplification. In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 16383–16408, Toronto, Canada. Association for Computational Linguistics.

OpenAI, Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altenschmidt, Sam Altman, Shyamal Anadkat, Red Avila, Igor Babuschkin, Suchir Balaji, Valerie Balcom, Paul Baltescu, Haiming Bao, Mohammad Bavarian, Jeff Belgum, and 262 others. 2024. GPT-4 Technical Report. *Preprint*, arXiv:2303.08774.

Kishore Papineni, Salim Roukos, Todd Ward, and Wei-Jing Zhu. 2002. Bleu: A Method for Automatic Evaluation of Machine Translation. In *Proceedings of the 40th Annual Meeting on Association for Computational Linguistics*, ACL '02, page 311–318, USA. Association for Computational Linguistics.

Jipeng Qiang, Minjiang Huang, Yi Zhu, Yunhao Yuan, Chaowei Zhang, and Kui Yu. 2025. Redefining Simplicity: Benchmarking Large Language Models from Lexical to Document Simplification. *Preprint*, arXiv:2502.08281.

Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, and Peter J. Liu. 2020. Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer. *Journal of Machine Learning Research*, 21:1–67.

C. Spearman. 1904. The Proof and Measurement of Association between Two Things. *The American Journal of Psychology*, 15(1):72–101.

Regina Stodden. 2024a. EASSE-DE: Easier Automatic Sentence Simplification Evaluation for German. *Preprint*, arXiv:2404.03563.

Regina Stodden. 2024b. Reproduction & Benchmarking of German Text Simplification Systems. In *Proceedings of the Workshop on DeTermIt! Evaluating Text Difficulty in a Multilingual Context @ LREC-COLING 2024*, pages 1–15, Torino, Italia. ELRA and ICCL.

Regina Stodden, Omar Momen, and Laura Kallmeyer. 2023. DEplain: A German Parallel Corpus with Intralingual Translations into Plain Language for Sentence and Document Simplification. In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 16441–16463, Toronto, Canada. Association for Computational Linguistics.

Elior Sulem, Omri Abend, and Ari Rappoport. 2018. BLEU is Not Suitable for the Evaluation of Text Simplification. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*, pages 738–744, Brussels, Belgium. Association for Computational Linguistics.

Teerapaun Tanprasert and David Kauchak. 2021. Flesch-kincaid is Not a Text Simplification Evaluation Metric. In *Proceedings of the First Workshop on Natural Language Generation, Evaluation, and Metrics (GEM)*, pages 1–14, Online. Association for Computational Linguistics.

Irina Temnikova. 2012. *Text Complexity and Text Simplification*. PhD Thesis, University of Wolverhampton.

Shih-Hung Wu and Hong-Yi Huang. 2023. A Prompt Engineering Approach to Scientific Text Simplification: CYUT at SimpleText2023 Task3. In *CLEF 2023: Conference and Labs of the Evaluation Forum*, Thessaloniki, Greece.

Wei Xu, Chris Callison-Burch, and Courtney Napoles. 2015. Problems in Current Text Simplification Research: New Data Can Help. *Transactions of the Association for Computational Linguistics*, 3:283–297.

Wei Xu, Courtney Napoles, Ellie Pavlick, Quanze Chen, and Chris Callison-Burch. 2016. Optimizing Statistical Machine Translation for Text Simplification. *Transactions of the Association for Computational Linguistics*, 4:401–415.

Tianyi Zhang, Varsha Kishore, Felix Wu, Kilian Q. Weinberger, and Yoav Artzi. 2020. Bertscore: Evaluating Text Generation with BERT. *Preprint*, arXiv:1904.09675.

Sanja Štajner, Maja Popović, Horacio Saggion, Lucia Specia, and Mark Fishel. 2016. Shared Task on Quality Assessment for Text Simplification.

Appendix

A DEPlain Corpus – Example

Original: "[...] Mathematik-Matura in Österreich wurde geändert. Wien Am Montag beginnt für viele Schüler die Zentral-Matura. Besonders genau beobachtet werden die Ergebnisse der Mathematik-Prüfungen. Im Jahr 2018 haben rund 20 Prozent der Schüler die Mathematik-Prüfungen nicht geschafft. Das ist sehr viel. Darum wurden dieses Jahr die Mathematik-Prüfungen geändert. Die Aufgaben sollen verständlicher erklärt sein, damit der Text die Schüler nicht mehr verwirrt. Erklärung: Zentral-Matura. Sehr viele Schüler machen am Ende ihrer Schulzeit eine große Prüfung. Das ist die Matura. Seit einigen Jahren bekommen alle Matura-Schüler in ganz Österreich die gleichen Fragen bei der Prüfung. Darum spricht man von der Zentral-Matura. [...]"

Simplified: "[...] In Österreich beginnt am Montag die Zentral-Matura. Wien In Österreich beginnen am Montag die Zentral-Matura-Prüfungen. Für die Mathematik-Prüfungen gibt es nun einige Änderungen. Der Grund ist, dass im Jahr 2018 viele Schüler die Mathematik-Prüfungen nicht geschafft haben. In Zukunft werden die Aufgaben verständlicher geschrieben. Erklärung: Zentral-Matura. Sehr viele Schüler machen mit 18 Jahren eine große Prüfung. Das ist die Matura. Seit einigen Jahren bekommen alle Matura-Schüler in ganz Österreich die gleichen Prüfungs-Fragen. Darum spricht man von der Zentral-Matura. [...]"

Example 1: Original text and corresponding simplification from DEPlain-APA, shortened

B Prompt Templates

Template	English Version, 0-Shot
TURK	You are required to simplify the original text by using simpler concepts, words, or phrases. Please keep the meaning the same. Only provide one result. Original text: cc.textArray[1] Simplified text:
ASSET	You are required to simplify the original text by applying different transformations. Please keep the meaning the same. Only provide one result. Original text: cc.textArray[1] Simplified text:
Newsela	You are required to simplify the original text. You can delete information that makes the text difficult to understand. Only provide one result. Original text: cc.textArray[1] Simplified text:
Wu & Huang	Your task is to simplify the following text to make it easier to understand. Please note that your response should be flexible enough to allow for various relevant and creative simplifications, as long as they accurately convey the intended meaning. Original text: cc.textArray[1] Simplified text:
Capito	##Persona You are a professional at simplifying texts. Your expertise is in rewriting German texts for learners at CEFR level A2. ##Instruction Your task is to simplify the following newspaper article marked by triple backticks. ###You MUST follow these rules: 1. Use short, clear sentences. 2. Break up long sentences and those with subordinate clauses. 3. Use only short, everyday words. 4. Split compound words with hyphens if it improves readability. 5. Replace difficult or technical words with simple explanations. Omit them if they are not essential. 6. Use one word per concept. Do not use synonyms. 7. Replace personal pronouns in the third person with the noun they refer to. 8. Use the Perfekt tense to describe past events. Use Präsens (present tense) for general facts or current situations. 9. Write in the indicative mood only. 10. Avoid passive voice unless the passive form is more common and easier to understand. 11. Write out all abbreviations. 12. Do not use metaphors or figurative language. 13. Use "nicht" for negation. ###Output format: Return the answer in plain text. ##Input Original text: "'cc.textArray[1]"' Simplified text:

Table 3: Different prompt templates, English, 0-Shot

Template	German Version, 0-Shot
TURK	Bitte vereinfache den Originaltext, indem du einfachere Konzepte, Wörter oder Phrasen verwendest. Bitte behalte die Bedeutung des Textes bei. Gib nur ein Ergebnis an. Originaltext: cc.textArray[1] Vereinfachung:
ASSET	Bitte vereinfache den Originaltext, indem du verschiedene Umformungen vornimmst. Bitte behalte die Bedeutung des Textes bei. Gib nur ein Ergebnis an. Originaltext: cc.textArray[1] Vereinfachung:
Newsela	Bitte vereinfache den Originaltext. Streiche Informationen, die das Verständnis des Textes erschweren. Gib nur ein Ergebnis an. Originaltext: cc.textArray[1] Vereinfachung:
Wu & Huang	Bitte vereinfache den folgenden Text so, dass er leichter zu verstehen ist. Beachte bitte, dass die Antwort flexibel genug sein sollte, um verschiedene relevante und kreative Vereinfachungen zuzulassen, solange sie die beabsichtigte Bedeutung genau wiedergeben. Originaltext: cc.textArray[1] Vereinfachung:
Capito	##Rolle Du bist Fachperson für das Vereinfachen von Texten. Du bist darauf spezialisiert, deutsche Texte für Lernende auf dem Sprachniveau A2 (GER) umzuformulieren. ##Aufgabe Deine Aufgabe ist es, den folgenden Zeitungsartikel, der mit drei Rückstrichen ("') markiert ist, zu vereinfachen. ###Du MUSST dabei folgende Regeln einhalten: 1. Verwende kurze, klare Sätze. 2. Zerlege lange Sätze und Sätze mit Nebensätzen in mehrere Hauptsätze. 3. Verwende nur kurze, alltägliche Wörter. 4. Trenne zusammengesetzte Wörter mit Bindestrichen, wenn es die Lesbarkeit verbessert. 5. Ersetze schwierige oder fachliche Wörter durch einfache Erklärungen. Lass sie weg, wenn sie nicht nötig sind. 6. Verwende für jedes Konzept nur ein Wort. Keine Synonyme verwenden. 7. Ersetze Personalpronomen in der dritten Person durch die Nomen, auf die sie sich beziehen. 8. Verwende das Perfekt für vergangene Ereignisse. Nutze das Präsens, um allgemeine Aussagen oder aktuelle Situationen zu beschreiben. 9. Schreibe nur im Indikativ. 10. Vermeide das Passiv, außer es ist gebräuchlich und leichter verständlich. 11. Schreibe alle Abkürzungen aus. 12. Verwende keine Metaphern oder bildliche Sprache. 13. Verneine mit „nicht". ###Ausgabeformat: Gib die Antwort im Klartext zurück. ## Input Originaltext: "'cc.textArray[1]"' Vereinfachung:

Table 4: Different prompt templates, German, 0-Shot

C Prompt Engineering – Analysis

Template/ Language/ # Examples	BLEU ↑	SARI ↑	BS-P ↑	FRE ↑	WSTF1 ↓	Comp. Ratio ↓	Sentence Splits ↑	Avg. sent. length ↓	Avg. word length ↓	Avg. time ↓
turk	13.24	39.36	0.42	62.29	7.26	0.68	0.70	11.37	**1.77**	7.44
asset	9.26	37.58	0.38	56.31	8.53	0.58	0.50	12.92	1.85	6.77
newsela	4.37	35.14	0.35	56.09	8.55	**0.39**	0.34	12.79	1.87	**5.37**
wu_huang	9.44	37.73	0.37	60.78	7.59	0.60	0.59	12.07	**1.77**	8.02
capito	**21.57**	**42.97**	**0.52**	**65.59**	**6.60**	0.78	**0.95**	**9.03**	1.78	6.92
English	10.99	37.82	0.39	**60.23**	7.72	0.61	**0.64**	**11.32**	**1.80**	7.29
German	**12.16**	**39.29**	**0.42**	60.19	**7.69**	**0.60**	0.59	11.95	1.81	**6.51**
0	7.23	35.66	0.35	**60.71**	**7.61**	**0.50**	0.53	12.12	**1.79**	**5.83**
1	12.53	39.28	0.42	59.85	7.77	0.63	0.63	11.66	1.82	6.98
3	**14.96**	**40.73**	**0.45**	60.08	7.74	0.69	**0.69**	**11.12**	1.82	7.89
Original	33.84	17.50	0.57	61.24	7.43	1.00	1.00	10.79	1.83	n/a
Reference	100.00	100.00	1.00	66.55	6.39	0.91	1.06	9.65	1.76	n/a

Table 5: Scores of the automatic metrics (BS-P = BERTScore-Precision, FRE = Flesch Reading Ease, WSTF1 = Wiener Sachtextformel 1) grouped by prompt template, language and number of examples used; the best values for each group are written in **bold**; baselines for comparison

		BLEU +	Rank BLEU	SARI +	Rank SARI	bertscore_ precision +	Rank BERT	FRE +	Rank FRE	Wiener-Sachtext formel-1 -	Rank WSTF	Compression ratio	Sentence splits	Avg. sentence length (in words)	Avg. number syllables per word	avg_time (sec.)	error_pct (%)	OVERALL RANK
32	Reference baseline (tgt2tgt)	100,00	1	100,00	1	1,00	1	66,55	1	6,39	1	0,91	1,06	9,65	1,76	0,00	0,00	5
30	capito_de_3.txt	21,95	5	**43,89**	2	**0,53**	4	65,90	4	6,54	3	0,78	0,95	9,15	1,77	6,24	1,25	18
28	capito_de_1.txt	**22,62**	4	43,42	3	0,53	5	65,71	5	6,59	5	0,81	**0,98**	9,13	1,77	5,89	1,04	22
26	capito_de_0.txt	20,36	9	43,18	4	0,51	8	**66,47**	2	**6,42**	2	0,76	0,93	9,27	1,75	5,87	0,62	25
29	capito_en_3.txt	21,64	7	43,11	5	0,52	6	65,53	6	6,61	6	0,77	0,95	8,77	1,78	8,18	2,92	30
27	capito_en_1.txt	21,84	6	42,45	6	0,52	7	65,08	7	6,69	7	0,78	0,97	**8,77**	1,79	8,34	2,92	33
25	capito_en_0.txt	21,02	8	41,77	8	0,51	9	64,86	9	6,73	8	0,78	0,94	9,09	1,79	7,03	2,50	42
4	turk_de_1.txt	16,44	11	41,39	9	0,47	11	61,64	11	7,38	11	0,72	0,69	11,82	1,78	7,37	0,00	53
6	turk_de_3.txt	18,40	10	41,80	7	0,49	10	61,30	13	7,44	14	0,77	0,75	11,34	1,79	6,51	0,00	54
5	turk_en_3.txt	16,18	12	41,12	10	0,46	12	60,86	15	7,56	16	0,72	0,72	10,96	1,80	9,68	1,88	65
31	Identity baseline (src2src)	33,84	2	17,50	33	0,57	3	61,24	14	7,43	13	1,00	1,00	10,79	1,83	0,00	0,00	65
3	turk_en_1.txt	13,79	14	39,73	15	0,43	16	61,58	12	7,39	12	0,70	0,72	11,12	1,78	8,17	1,04	69
33	Truncate baseline	29,51	3	27,82	32	0,57	2	60,68	17	7,54	15	0,82	0,83	10,47	1,84	0,00	0,00	69
24	wu_huang_de_3.txt	13,42	16	40,78	11	0,44	14	60,16	18	7,72	18	0,67	0,64	11,70	1,79	7,85	1,25	77
2	turk_de_0.txt	9,63	21	38,98	18	0,38	21	62,18	10	7,25	10	0,55	0,49	12,97	1,75	6,49	0,00	80
23	wu_huang_en_3.txt	13,52	15	40,53	12	0,44	15	59,50	20	7,84	21	0,69	0,64	12,03	1,80	7,61	0,21	83
12	asset_de_3.txt	14,60	13	39,99	13	0,45	13	57,63	23	8,24	23	0,73	0,65	11,93	1,84	9,40	2,29	85
22	wu_huang_de_1.txt	11,67	19	39,92	14	0,41	18	59,94	19	7,75	19	0,63	0,58	12,20	1,79	7,16	0,00	89
1	turk_en_0.txt	4,99	25	33,11	28	0,30	31	66,17	3	6,55	4	0,62	0,80	9,99	1,69	6,43	2,29	91
21	wu_huang_en_1.txt	11,20	20	38,79	19	0,40	20	60,73	16	7,58	17	0,67	0,65	12,04	1,77	8,39	0,00	92
10	asset_de_1.txt	11,80	18	39,09	17	0,41	19	56,71	25	8,40	25	0,66	0,56	13,00	1,84	7,38	0,00	104
11	asset_en_3.txt	11,95	17	39,24	16	0,42	17	55,81	29	8,64	28	0,66	0,59	12,06	1,86	8,21	0,62	107
18	newsela_de_3.txt	9,13	23	38,51	20	0,38	22	57,76	22	8,24	22	0,53	0,51	11,56	1,85	7,31	0,42	109
19	wu_huang_en_0.txt	2,40	31	30,37	31	0,22	33	64,96	8	6,81	9	0,54	0,67	10,31	**1,67**	9,68	2,71	112
20	wu_huang_de_0.txt	4,41	27	35,98	23	0,31	29	59,37	21	7,82	20	0,42	0,34	14,16	1,77	7,42	0,42	120
17	newsela_en_3.txt	8,81	24	38,32	21	0,38	23	56,31	27	8,55	27	0,54	0,50	11,73	1,87	7,96	0,21	122
8	asset_de_0.txt	4,83	26	35,73	24	0,32	28	56,78	24	8,40	24	0,45	0,34	14,31	1,83	4,28	0,00	126
9	asset_en_1.txt	9,35	22	38,11	22	0,38	24	55,07	32	8,78	33	0,59	0,52	12,44	1,87	6,28	0,00	133
16	newsela_de_1.txt	2,47	30	34,42	26	0,33	27	56,38	26	8,46	26	0,33	0,29	13,06	1,88	5,66	0,00	135
15	newsela_en_1.txt	4,13	28	35,46	25	0,33	26	55,61	30	8,65	29	0,40	0,35	13,02	1,88	5,18	0,00	138
7	asset_en_0.txt	3,02	29	33,30	27	0,28	32	55,85	28	8,71	31	0,41	0,35	13,76	1,84	5,07	0,00	147
14	newsela_de_0.txt	0,67	33	32,20	29	0,35	25	54,96	33	8,73	32	**0,24**	0,19	13,68	1,89	**2,89**	0,00	152
13	newsela_en_0.txt	0,99	32	31,94	30	0,31	30	55,53	31	8,69	30	0,27	0,22	13,66	1,87	3,20	0,00	153

Figure 2: Scores of the automatic metrics and text statistics for the individual prompts, ranked by "OVERALL RANK"; the best values are written in red and bold; the different prompt templates are color-coded (TURK = red, ASSET = yellow, Newsela = green, Wu & Huang = blue, Capito = purple); baselines for comparison (identity baseline = original text, reference baseline = reference simplification)

D Model Evaluation – Analysis

Original: "[...] Die Inflation wurde in Österreich niedriger . Wien Die Inflation in Österreich ist im April etwas niedriger gewesen als im März . Insgesamt wurde das Leben in Österreich um 1,7 Prozent teurer . Teurer wurden vor allem Mieten , Wasser und Energie . Auch Restaurants und Hotels verteuerten sich im April . Leicht billiger wurden Dinge , die man in der Freizeit macht . Am stärksten verbilligten sich im April Urlaubs-Reisen . Erklärung : Inflation . Man bemerkt die Inflation daran , dass alles teurer wird . Deshalb nennt man sie auch Teuerung . Ist die Inflation niedrig , steigen die Preise nur leicht . Ist die Inflation hoch , dann steigen die Preise stärker . Bei Inflation wird das Geld immer weniger wert . Deshalb braucht man mehr Geld , wenn man sich etwas kaufen will . [...]"

Reference: "[...] Die Inflation ist in Österreich im April schwächer gewesen. Die Inflation in Österreich ist im April niedriger gewesen als im März. Das heißt, viele Dinge sind nicht viel teurer geworden. Manche Dinge sind aber deutlich teurer geworden. Zum Beispiel Mieten, Wasser, Strom, Heizöl und Gas. Deutlich teurer wurden auch Essen im Lokal und Wohnen im Hotel. Manches wurde aber auch billiger. Urlaubs-Reisen wurden sogar viel billiger. Erklärung: Inflation. Man bemerkt die Inflation daran, dass alles teurer wird. Deshalb nennt man sie auch Teuerung. Ist die Inflation niedrig,steigen die Preise nur leicht. Wenn die Inflation hoch ist, dann steigen die Preise stärker. Bei Inflation wird das Geld immer weniger wert. Deshalb braucht man mehr Geld, wenn man sich etwas kaufen will. [...]"

ChatGPT-4o "[...] Die Inflation in Österreich ist niedriger geworden . Wien Die Inflation ist im April etwas niedriger gewesen als im März . Alles wurde um 1,7 Prozent teurer . Mieten , Wasser und Energie wurden teurer . Auch Restaurants und Hotels wurden teurer . Freizeit-Dinge wurden etwas billiger . Urlaubs-Reisen wurden am meisten billiger . Erklärung : Inflation . Inflation bedeutet , dass alles teurer wird . Darum nennt man sie auch Teuerung . Wenn die Inflation niedrig ist , steigen die Preise nur leicht . Wenn die Inflation hoch ist , steigen die Preise stark . Bei Inflation wird das Geld weniger wert . Man braucht mehr Geld , um etwas zu kaufen . [...]"

Example 2: Example of a GPT-4o simplification, original text and reference simplification for comparison, shortened

Original: "[...] Vor 50 Jahren fand die erste bemannte Mondlandung statt . Wien Heuer ist das 50. Jubiläum der ersten bemannten Mondlandung . Am 21. Juli 1969 , also am Sonntag vor genau 50 Jahren , betrat der erste Mensch den Mond . Es war der Astronaut Neil Armstrong aus den USA . Als er den Mond betrat , sagte er : " Das ist ein kleiner Schritt für einen Menschen , aber ein großer Sprung für die Menschheit . " . Kurz nach Armstrong betrat auch der Astronaut Buzz Aldrin den Mond . Armstrong und Aldrin waren insgesamt rund 21 Stunden auf dem Mond . In den folgenden Jahren landeten noch 5 Mal US-Astronauten auf dem Mond . Die letzte bemannte Mondlandung fand 1972 statt . [...]"

Reference: "[...] Vor genau 50 Jahren landeten die ersten Menschen auf dem Mond. Wien Heuer feiert man ein wichtiges Ereignis. Vor 50 Jahren gelang die erste Landung von Astronauten auf dem Mond. Am Sonntag vor genau 50 Jahren machten 2 Astronauten die ersten Schritte auf dem Mond. Die Astronauten kamen aus den USA und hießen Neil Armstrong und Buzz Aldrin. Neil Armstrong und Buzz Aldrin blieben fast einen ganzen Tag lang auf dem Mond. Dann flogen sie wieder zur Erde zurück. In den Jahren darauf landeten noch andere Astronauten aus den USA auf dem Mond. Zum letzten Mal landeten Menschen im Jahr 1972 auf dem Mond. [...]"

Claude 3.5 Sonnet "[...] Vor 50 Jahren landete der erste Mensch auf dem Mond . Wien Dieses Jahr ist der 50. Jahrestag der ersten Mondlandung mit Menschen . Am 21. Juli 1969 betrat Neil Armstrong als erster Mensch den Mond . Er sagte : " Das ist ein kleiner Schritt für einen Menschen , aber ein großer Sprung für die Menschheit . " Kurz darauf folgte ihm Buzz Aldrin . Beide Astronauten waren etwa 21 Stunden auf dem Mond . Danach landeten noch fünf weitere Male US-Astronauten auf dem Mond . Die letzte bemannte Mondlandung war 1972. [...]"

Example 3: Example of a Claude 3.5 Sonnet simplification, original text and reference simplification for comparison, shortened

E Readability Survey – Instructions

Example Text, Readability 1 (Complex): Der Mai verlief bislang ungewöhnlich kühl. Tatsächlich könnte dieser Monat zu den kältesten Mai-Monaten der vergangenen vier Jahrzehnte zählen – das berichten Meteorologinnen und Meteorologen. In den letzten Jahren war der Mai häufig von frühsommerlichen Temperaturen geprägt. Für die Landwirtschaft hatte das bisherige Wetter jedoch durchaus positive Effekte: Im Vergleich zum Durchschnitt fiel in diesem Mai deutlich mehr Regen. Auch in den kommenden Tagen ist weiterhin mit unbeständigem und eher kühlem Wetter zu rechnen. Zum Ende der Woche hin könnten die Temperaturen allerdings wieder etwas ansteigen.

Example Text, Readability 5 (Simple): Der Mai ist kalt. In diesem Jahr ist der Mai kälter als sonst. Vielleicht ist es der kälteste Mai seit 40 Jahren. Das sagen Wetter-Experten. In den letzten Jahren war der Mai warm. Für die Bauern ist das kalte Wetter gut. Es hat im Mai mehr geregnet als sonst. In den nächsten Tagen regnet es weiter. Es bleibt kühl. Am Ende der Woche kann es etwas wärmer werden.

Example 4: Examples of simple and complicated texts shown to the participants in the introduction of the survey

F Readability Survey – Evaluation

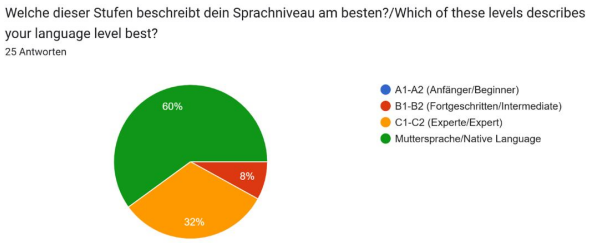


Figure 3: Distribution of study participants according to their language proficiency

Model	**Avg. Score ↑**
Gemini 2.5 Flash	4.13
ChatGPT-4	4.13
Llama 3.1 405B	3.88
ChatGPT-4o	3.88
Claude 3.5 Sonnet	3.63
Mistral 7B Instruct	3.38
Claude 3.5 Haiku	3.38
ChatGPT-3.5 Turbo	3.13
Deepseek v3	3.00
Reference	2.89
Original	2.78

Table 6: Average readability score, B1/B2 level

Model	**Avg. Score ↑**
Gemini 2.5 Flash	4.53
ChatGPT-4	4.28
Deepseek v3	4.19
ChatGPT-3.5 Turbo	4.13
Llama 3.1 405B	4.00
ChatGPT-4o	3.88
Mistral 7B Instruct	3.72
Claude 3.5 Haiku	3.63
Claude 3.5 Sonnet	3.44
Reference	3.40
Original	2.97

Table 7: Average readability score, C1/C2 level

Model	**Avg. Score ↑**
Gemini 2.5 Flash	4.60
ChatGPT-4	4.50
Deepseek v3	4.20
Llama 3.1 405B	4.18
ChatGPT-3.5 Turbo	4.10
ChatGPT-4o	3.82
Mistral 7B Instruct	3.80
Claude 3.5 Haiku	3.62
Claude 3.5 Sonnet	3.58
Reference	3.32
Original	3.25

Table 8: Average readability score, native speakers

Source/Model	Score	Text
GPT-3.5 Turbo	4.88	Das Formel-1-Rennen in Monaco wurde wegen der Corona-Krise abgesagt. Es sollte am 24. Mai stattfinden. Auch Rennen in den Niederlanden und Spanien wurden verschoben. Das erste Rennen soll jetzt am 7. Juni in Aserbaidschan stattfinden.
GPT-4	4.84	In Ancona, einer Stadt in Italien, gab es ein großes Feuer im Hafen. Niemand wurde verletzt, aber es gab eine große Rauchwolke. Die Menschen sollten drinnen bleiben, während die Feuerwehr das Feuer löschte.
Deepseek v3	4.80	Im Tiergarten Schönbrunn in Wien wurde ein Elefantenbaby geboren. Es kann ab Freitag täglich von 10 bis 11 Uhr besucht werden. Der Name des Babys wird online gewählt; zur Auswahl stehen Phinda, Kibali und Dunia. Die Elefanten sind afrikanische Elefanten.

Table 9: Top 3 texts in terms of readability score

Source/Model	Score	Text
Original	2.48	Regierung verschärft Maßnahmen gegen Corona-Virus. Wien Die Regierung in Österreich hat am Montag schärfere Maßnahmen wegen dem Corona-Virus verkündet. Supermärkte dürfen bald nur noch mit einem Mund-Nasen-Schutz betreten werden. Diese Maßnahme beginnt, sobald genug Masken in den Supermärkten verteilt werden können. Das soll am Mittwoch soweit sein. Die Masken werden dann am Eingang verteilt. Das sagte Bundeskanzler Sebastian Kurz. Menschen die durch den Corona-Virus besonders gefährdet sind, müssen nicht mehr in die Arbeit fahren. Sie können von zuhause aus arbeiten oder bekommen frei. Außerdem verkündete die Regierung, dass Hotels in Österreich schließen müssen. Kurz warnte davor, die Maßnahmen zu früh aufzuheben. Er sprach von der "Ruhe vor dem Sturm". Die Regierung bat die Menschen, die Maßnahmen zu befolgen, damit sich der Virus nicht noch weiter ausbreiten kann. Man darf also wirklich nur dann nach draußen gehen, wenn man in die Arbeit muss oder Lebensmittel einkaufen geht. Auch zum Spazierengehen darf man hinaus. Draußen muss man mindestens einen Meter Abstand zu anderen Menschen halten.
Original	2.64	Viele Fußgänger-Unfälle auf Zebrastreifen. Wien Im Jahr 2019 sind auf den Zebrastreifen in Österreich viele Unfälle geschehen. So wurden 12 Fußgänger getötet und 1.225 Fußgänger verletzt. Dabei sollten Zebrastreifen doch Fußgängern ermöglichen, sicher über die Straße zu gehen. Der Verkehrsclub Österreich kennt einige Ursachen für diese vielen Unfälle. So fahren Autos viel zu schnell. Laut Gesetz dürfen sich die Autos einem Zebrastreifen aber nur so nähern, dass sie jederzeit abbremsen können. Je näher sie dem Zebrastreifen kommen, desto langsamer sollten sie also fahren. Das machen aber nicht alle Autofahrer. Auch parken Autos oft viel zu nah am Zebrastreifen. Weil die parkenden Autos den Zebrastreifen verdecken, sehen andere Autofahrer die Menschen am Zebrastreifen oft sehr spät. Vom Gesetz her dürfen Autos 5 Meter vor dem Zebrastreifen nicht parken. Der Verkehrsclub Österreich fordert, dass sie 10 Meter vor dem Zebrastreifen nicht parken dürfen.
Original	2.76	334 Menschen bei Razzia gegen Mafia in Italien festgenommen. Rom In Italien gibt es mehrere große Gruppen von Verbrechern. Alle diese Gruppen zusammen nennt man Mafia. Die Mafia ist gut organisiert und macht auf der ganzen Welt kriminelle Geschäfte. Bei einer Razzia gegen diese Mafia-Gruppen sind in Italien, Deutschland, der Schweiz und Bulgarien jetzt 334 Menschen festgenommen werden. Diese Menschen sollen zum Beispiel Morde, Erpressungen und Geldwäsche durchgeführt haben. Die Polizei fand auch 15 Millionen Euro Bargeld. Erklärung: Razzia. Wenn die Polizei glaubt, dass in bestimmten Gebäuden Sachen oder Menschen versteckt werden, kann sie eine Razzia machen. Sie kann dann die Gebäude durchsuchen. Möglicherweise findet die Polizei dadurch unerlaubte Dinge wie Drogen oder Waffen. Oder sie findet Personen, die sich vor der Polizei verstecken. Eine Razzia wird meistens genau geplant, damit niemand entwischen kann. Für eine Razzia muss es aber gute Gründe geben. Sonst darf die Polizei nicht so einfach Gebäude durchsuchen. Erklärung: Geldwäsche. Bei Geldwäsche geht es um Geld, das nicht legal verdient wurde. Zum Beispiel bei kriminellen Geschäften. Oder um Geld, das man versteckt, damit man keine Steuern zahlen muss. Damit man dieses Geld normal im Alltag verwenden kann, muss es gewaschen werden. Das heißt aber nicht, dass es in die Waschmaschine kommt. Sondern manche Banken helfen dabei, dass das illegale Geld vor den Behörden versteckt wird. Zum Beispiel, indem man das illegale Geld ins Ausland schickt und erst später wieder zurückholt.

Table 10: Bottom 3 texts in terms of readability score

The following paragraphs take an exemplary view on the performance of the generative language models on the source texts rated by the study participants as most difficult or easiest. Diagrams showing the performance of the LLMs on the other texts from the survey can be found in Appendix H.

Model	Score
Original	2,48
Reference	3,08
GPT-4	4,32
GPT-4o	3,56
Claude 3.5 Haiku	2,96
Deepseek v3	3,36

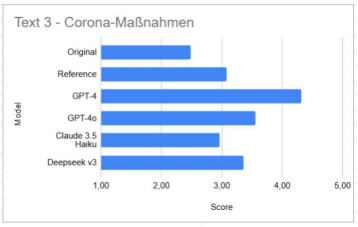


Figure 4: Readability scores of the LLMs for the most difficult rated source text

The text on the coronavirus measures in Table 10 was rated as the most difficult to read with a readability score of 2.48. In addition to the reference simplification by the Capito employees, the simplifications of the following randomly selected models were considered for comparison: GPT-4, GPT-4o, Claude 3.5 Haiku and Deepseek v3 (Figure 4). The reference already offers a significant improvement in the readability value to 3.08, which even surpasses the result of the Claude model (2.96). With Deepseek v3, a further significant improvement can be achieved (3.36) and GPT-4o is even more ahead (3.56). However, GPT-4 is in first place by a wide margin, 0.76 readability points ahead of the second-placed model. The score of 4.32 is 1.24 points better than the reference and 1.84 points easier to read than the original text. GPT-4 thus confirms its position as one of the two leading models for text simplification and is therefore also suitable for simplifying texts to a greater extent. In this difficult example, the other models have problems keeping up with their values from the overall evaluation (Table 2) and all achieve significantly lower values.

Model	Score
Original	3,68
Reference	3,76
GPT-4	4,36
GPT-4o	3,84
Deepseek v3	3,88
Gemini 2.5 Flash	4,56

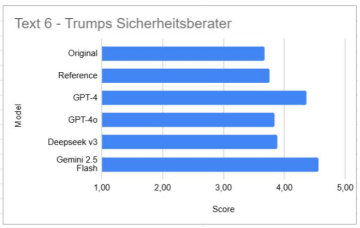


Figure 5: Readability scores of the LLMs for the easiest rated source text

The original version of Text 6 about Trump's security advisor (see Appendix G), on the other hand, was rated as the easiest to read by the subjects. In addition to the reference, simplifications of GPT-4, GPT-4o, Deepseek v3 and Gemini 2.5 Flash are considered here (Figure 5). As already mentioned, it is pure coincidence that three of the four models considered match those from the previous example. Here, the original text achieves a value of 3.68. Reference (3.76), GPT-4o (3.84) and Deepseek v3 (3.88) achieve only slight improvements in the simplicity of the text. GPT-4 generates a text of almost the same perceived difficulty as in the previous example, clearly outperforms the models considered so far with a value of 4.36 and confirms its suitability for simplifying texts of varying difficulty. However, Gemini 2.5 Flash towers above them all with a score of 4.56, thus cementing its status as THE leading model in the eyes of the study participants.

G Readability Survey – All Texts Used

Text 1

Original: Dominic Thiem gewinnt als erster Österreicher die US Open. Österreichs bester Tennis-Spieler Dominic Thiem hat in New York seinen bis jetzt größten Sieg gefeiert. Der Niederösterreicher gewann das Finale der US Open. Die US Open sind eines der wichtigsten Tennis-Turniere des Jahres. Thiem besiegte im Finale den Deutschen Alexander Zverev. Das Spiel war sehr spannend und dauerte über 4 Stunden. Am Anfang war Zverev der klar bessere Spieler, Thiem wurde dann aber immer stärker und gewann. Das ist vorher noch keinem Österreicher gelungen. Für seinen Sieg erhielt Thiem ein Preisgeld von 3 Millionen Dollar.

Reference: Dominic Thiem feiert seinen bis jetzt größten Sieg. New York Dominic Thiem ist im Moment der beste Tennis-Spieler aus Österreich. Am Sonntag hat Thiem seinen bis jetzt größten Sieg gefeiert. Thiem gewann das Finale beim Tennis-Turnier in New York. Er besiegte im Finale den deutschen Spieler Alexander Zverev. Das Spiel war sehr spannend und dauerte über 4 Stunden. Am Anfang war Zverev klar besser, dann wurde aber Thiem immer stärker. Thiem ist der erste Österreicher, der das Turnier in New York gewinnen konnte. Für seinen Sieg bekommt Thiem rund 2,5 Millionen Euro. Das ist sein bis jetzt höchstes Preisgeld.

Claude 3.5 Haiku: Dominic Thiem gewinnt die US Open. Der österreichische Tennis-Spieler Dominic Thiem hat in New York die US Open gewonnen. Er ist der erste Österreicher, dem das gelingt. Im Finale besiegte er den Deutschen Alexander Zverev nach einem spannenden Spiel, das über 4 Stunden dauerte. Für seinen Sieg bekam Thiem 3 Millionen Dollar Preisgeld.

Claude 3.5 Sonnet: Dominic Thiem gewinnt als erster Österreicher die US Open. Dominic Thiem, der beste Tennis-Spieler aus Österreich, hat in New York seinen größten Erfolg erzielt. Er gewann das Finale der US Open, einem der wichtigsten Tennis-Turniere des Jahres. Thiem besiegte den deutschen Spieler Alexander Zverev in einem spannenden Spiel, das mehr als 4 Stunden dauerte. Zverev war zu Beginn besser, aber Thiem wurde stärker und gewann. Kein Österreicher hat das zuvor geschafft. Thiem erhielt 3 Millionen Dollar Preisgeld für seinen Sieg.

Mistral 7B Instruct: Dominic Thiem gewinnt als erster Österreicher die US Open. Der beste Tennis-Spieler aus Österreich, Dominic Thiem, hat seinen größten Sieg in New York gefeiert. Thiem gewann das Finale der US Open, eines der wichtigsten Tennis-Turniere des Jahres. Im spannenden Endspiel besiegte er den Deutschen Alexander Zverev nach über 4 Stunden Spielzeit. Thiem war der erste Österreicher, dem das gelang. Für seinen Sieg erhielt er 3 Millionen Dollar.

Gemini 2.5 Flash: Dominic Thiem ist der erste Österreicher, der die US Open gewonnen hat. In New York feierte er seinen bisher größten Erfolg. Thiem besiegte im spannenden Finale den Deutschen Alexander Zverev nach über 4 Stunden. Zverev war anfangs besser, aber Thiem wurde stärker und gewann. Dafür erhielt er 3 Millionen Dollar Preisgeld.

Text 2

Original: Elefanten-Baby in Schönbrunn ab Freitag zu sehen. Wien Im Tiergarten Schönbrunn in Wien ist am Wochenende ein Elefanten-Baby geboren worden. Es ist ein Weibchen und noch ein bisschen wackelig auf den Beinen. Aber es spielt schon vergnügt mit Ästen und Holz-Spänen. Ab Freitag kann man das Elefanten-Baby jeden Tag von 10 bis 11 Uhr besuchen. Das Elefanten-Baby hat noch keinen Namen. Aber man kann auf der Internet-Seite des Tiergartens über den Namen abstimmen. Zur Auswahl stehen die afrikanischen Namen Phinda, Kibali und Dunia. Die Elefanten in Schönbrunn sind nämlich afrikanische Elefanten.

Reference: Das Elefanten-Baby in Schönbrunn kann man jetzt anschauen. Wien Im Tiergarten Schönbrunn in Wien ist am Samstag ein Elefanten-Baby geboren worden. Das Elefanten-Baby kann schon gehen. Es ist aber noch wackelig auf den Beinen. Trotzdem spielt es schon mit Ästen. Dabei kann man dem Elefanten-Baby ab Freitag zuschauen. Das geht immer am Vormittag von 10 Uhr bis 11 Uhr. Das Elefanten-Baby ist ein Mädchen und hat noch keinen Namen. Aber es soll bald einen Namen bekommen. Auf der Internet-Seite vom Tiergarten kann man einen von 3 Namen aussuchen. Die Namen sind Phinda, Kibali und Dunia.

Claude 3.5 Haiku: Elefanten-Baby in Schönbrunn ab Freitag zu sehen. Wien Im Tiergarten Schönbrunn in Wien wurde ein Elefanten-Baby geboren. Es ist ein weibliches Baby und noch etwas wackelig. Es spielt aber schon mit Ästen und Holzstücken. Ab Freitag kann man es jeden Tag von 10 bis 11 Uhr sehen. Es hat noch keinen Namen. Man kann auf der Internetseite des Tiergartens über den Namen abstimmen. Zur Auswahl stehen die afrikanischen Namen Phinda, Kibali und Dunia, denn die Elefanten in Schönbrunn sind afrikanische Elefanten.

Claude 3.5 Sonnet: Ein Elefanten-Baby kann ab Freitag im Wiener Tiergarten Schönbrunn besucht werden. Wien Im Tiergarten Schönbrunn wurde am Wochenende ein Elefanten-Baby geboren. Es ist ein weibliches Baby und noch etwas wackelig auf den Beinen, spielt aber schon mit Ästen und Holzspänen. Ab Freitag kann man es jeden Tag von 10 bis 11 Uhr besuchen. Das Baby hat noch keinen Namen, aber man kann online auf der Website des Tiergartens über den Namen abstimmen. Zur Auswahl stehen die afrikanischen Namen Phinda, Kibali und Dunia, da die Elefanten in Schönbrunn aus Afrika stammen.

Deepseek v3: Im Tiergarten Schönbrunn in Wien wurde ein Elefantenbaby geboren. Es kann ab Freitag täglich von 10 bis 11 Uhr besucht werden. Der Name des Babys wird online gewählt; zur Auswahl stehen Phinda, Kibali und Dunia. Die Elefanten sind afrikanische Elefanten.

Gemini 2.5 Flash: Im Tiergarten Schönbrunn in Wien wurde ein Elefanten-Baby geboren. Die kleine Elefantendame kann ab Freitag täglich von 10 bis 11 Uhr besucht werden. Sie hat noch keinen Namen, aber man kann online zwischen den Namen Phinda, Kibali und Dunia wählen. Die Elefanten in Schönbrunn sind afrikanische Elefanten.

Text 3

Original: Regierung verschärft Maßnahmen gegen Corona-Virus. Wien Die Regierung in Österreich hat am Montag schärfere Maßnahmen wegen dem Corona-Virus verkündet. Supermärkte dürfen bald nur noch mit einem Mund-Nasen-Schutz betreten werden. Diese Maßnahme beginnt, sobald genug Masken in den Supermärkten verteilt werden können. Das soll am Mittwoch soweit sein. Die Masken werden dann am Eingang verteilt. Das sagte Bundeskanzler Sebastian Kurz. Menschen die durch den Corona-Virus besonders gefährdet sind, müssen nicht mehr in die Arbeit fahren. Sie können von zuhause aus arbeiten oder bekommen frei. Außerdem verkündete die Regierung, dass Hotels in Österreich schließen müssen. Kurz warnte davor, die Maßnahmen zu früh aufzuheben. Er sprach von der "Ruhe vor dem Sturm". Die Regierung bat die Menschen, die Maßnahmen zu befolgen, damit sich der Virus nicht noch weiter ausbreiten kann. Man darf also wirklich nur dann nach draußen gehen, wenn man in die Arbeit muss oder Lebensmittel einkaufen geht. Auch zum Spazierengehen darf man hinaus. Draußen muss man mindestens einen Meter Abstand zu anderen Menschen halten.

Reference: In Österreich gibt es strengere Maßnahmen wegen dem Corona-Virus. Wien - In Österreich gibt es jetzt noch strengere Maßnahmen wegen dem Corona-Virus. Das hat die Regierung am Montag gesagt. In den Supermarkt darf man bald nur noch mit einer Stoff-Maske als Mund-Schutz. Diese Maßnahme soll ab Mittwoch gelten. Die Masken werden dann beim Eingang der Supermärkte verteilt. Das sagte Bundeskanzler Sebastian Kurz. Für manche Menschen ist der Corona-Virus besonders gefährlich. Diese Menschen müssen deshalb nicht mehr in die Arbeit fahren. Sie können von zuhause aus arbeiten. Wenn das nicht geht, bekommen sie frei. Die Regierung sagte außerdem, dass alle Hotels schließen müssen. Die Corona-Maßnahmen werden noch lange gelten. Kurz sprach von der "Ruhe vor dem Sturm". Das heißt, dass es bald schlimmer wird. Die Regierung bat die Menschen deshalb, dass sie die Maßnahmen befolgen. Nur so kann sich der Virus nicht noch weiter ausbreiten. Man darf wirklich nur dann nach draußen gehen, wenn es sein muss. Also wenn man in die Arbeit muss oder Lebensmittel einkaufen geht. Auch zum Spazierengehen darf man hinaus. Draußen muss man mindestes einen Meter Abstand zu anderen Menschen halten.

GPT-4: Die österreichische Regierung hat neue Regeln wegen des Corona-Virus angekündigt. In Supermärkte darf man bald nur mit Maske gehen. Die Masken werden ab Mittwoch am Eingang verteilt. Menschen, die vom Virus besonders gefährdet sind, müssen nicht mehr zur Arbeit fahren. Sie können von zuhause arbeiten oder bekommen frei. Hotels in Österreich müssen schließen. Bundeskanzler Sebastian Kurz warnte, die Regeln nicht zu früh zu lockern. Man soll nur rausgehen, wenn es nötig ist, z.B. zum Einkaufen oder Spazieren. Draußen soll man Abstand zu anderen halten.

GPT-4o: Regierung macht strengere Regeln gegen Corona-Virus. Wien Die Regierung in Österreich hat am Montag strengere Regeln wegen dem Corona-Virus gesagt. Man darf Supermärkte bald nur mit einem Mund-Nasen-Schutz betreten. Diese Regel beginnt, wenn genug Masken da sind. Das soll am Mittwoch passieren. Die Masken gibt es dann am Eingang. Das hat Bundeskanzler Sebastian Kurz gesagt. Menschen, die durch das Corona-Virus besonders gefährdet sind, müssen nicht mehr zur Arbeit fahren. Sie können von zuhause aus arbeiten oder bekommen frei. Auch Hotels in Österreich müssen schließen. Kurz hat gesagt, dass man die Regeln nicht zu früh stoppen soll. Die Regierung hat die Menschen gebeten, die Regeln zu befolgen. So kann sich das Virus nicht noch mehr ausbreiten. Man darf nur nach draußen gehen, wenn man zur Arbeit muss oder Essen einkaufen will. Auch Spazierengehen ist erlaubt. Draußen muss man mindestens einen Meter Abstand zu anderen Menschen halten.

Claude 3.5 Haiku: Die österreichische Regierung verschärft Maßnahmen gegen das Corona-Virus. Wien - Die Regierung hat am Montag strengere Regeln wegen des Corona-Virus angekündigt. Bald darf man Supermärkte nur noch mit einer Maske betreten. Diese Regel gilt, sobald genug Masken an die Supermärkte geliefert werden. Das soll am Mittwoch soweit sein. Die Masken werden am Eingang verteilt, sagte Bundeskanzler Sebastian Kurz. Besonders gefährdete Menschen müssen nicht zur Arbeit fahren. Sie können von zuhause arbeiten oder bekommen frei. Hotels in Österreich müssen schließen. Kurz warnte davor, die Regeln zu früh zu lockern. Er nannte es die "Ruhe vor dem Sturm". Die Regierung bittet die Menschen, die Regeln zu befolgen, damit sich das Virus nicht weiter ausbreitet. Man soll nur rausgehen, wenn es nötig ist, z.B. zur Arbeit oder zum Einkaufen. Beim Rausgehen soll man mindestens einen Meter Abstand zu anderen halten.

Deepseek v3: Österreichische Regierung verschärft COVID-19-Maßnahmen. Wien – Am Montag hat die österreichische Regierung strengere COVID-19-Maßnahmen angekündigt. Bald dürfen Supermärkte nur noch mit einer Gesichtsmaske betreten werden, die ab Mittwoch am Eingang verteilt wird. Bundeskanzler Sebastian Kurz erklärte, dass Personen mit hohem COVID-19-Risiko von zu Hause aus arbeiten oder Urlaub nehmen können. Die Regierung kündigte außerdem die Schließung von Hotels an. Kurz warnte vor einer zu frühen Aufhebung der Maßnahmen und bezeichnete diese als „Ruhe vor dem Sturm“. Die Bevölkerung wird gebeten, die Regeln zur Verhinderung einer weiteren Ausbreitung einzuhalten: das Haus nur zum Arbeiten, zum Einkaufen oder für Spaziergänge verlassen und einen Abstand von einem Meter zu anderen Personen einhalten.

Text 4

Original: 334 Menschen bei Razzia gegen Mafia in Italien festgenommen. Rom In Italien gibt es mehrere große Gruppen von Verbrechern. Alle diese Gruppen zusammen nennt man Mafia. Die Mafia ist gut organisiert und macht auf der ganzen Welt kriminelle Geschäfte. Bei einer Razzia gegen diese Mafia-Gruppen sind in Italien, Deutschland, der Schweiz und Bulgarien jetzt 334 Menschen festgenommen werden. Diese Menschen sollen zum Beispiel Morde, Erpressungen und Geldwäsche durchgeführt haben. Die Polizei fand auch 15 Millionen Euro Bargeld. Erklärung: Razzia. Wenn die Polizei glaubt, dass in bestimmten Gebäuden Sachen oder Menschen versteckt werden, kann sie eine Razzia machen. Sie kann dann die Gebäude durchsuchen. Möglicherweise findet die Polizei dadurch unerlaubte Dinge wie Drogen oder Waffen. Oder sie findet Personen, die sich vor der Polizei verstecken. Eine Razzia wird meistens genau geplant, damit niemand entwischen kann. Für eine Razzia muss es aber gute Gründe geben. Sonst darf die Polizei nicht so einfach Gebäude durchsuchen. Erklärung: Geldwäsche. Bei Geldwäsche geht es um Geld, das nicht legal verdient wurde. Zum Beispiel bei kriminellen Geschäften. Oder um Geld, das man versteckt, damit man keine Steuern zahlen muss. Damit man dieses Geld normal im Alltag verwenden kann, muss es gewaschen werden. Das heißt aber nicht, dass es in die Waschmaschine kommt. Sondern manche Banken helfen dabei, dass das illegale Geld vor den Behörden versteckt wird. Zum Beispiel, indem man das illegale Geld ins Ausland schickt und erst später wieder zurückholt.

Reference: Die Polizei in Italien verhaftete 334 Mitglieder von der Mafia. Rom - Im Land Italien gibt es große Gruppen von Verbrechern. Sie machen auf der ganzen Welt verbotene Geschäfte. Man nennt alle diese Gruppen zusammen auch Mafia. Die Polizei von Italien hat jetzt eine große Razzia gemacht. Dabei verhaftete die Polizei viele Mitglieder von der Mafia. Es waren 334 Mafia-Mitglieder. Sie sollen zum Beispiel Menschen ermordet oder erpresst haben. Erklärung: Razzia. Manchmal verstecken Verbrecher in Häusern verbotene Dinge oder gesuchte Personen. Wenn die Polizei deshalb die Häuser durchsucht, nennt man das Razzia. Dabei will die Polizei zum Beispiel Drogen oder Waffen finden. Eine Razzia wird genau geplant, damit niemand entwischen kann. Für eine Razzia muss die Polizei aber gute Gründe haben.

GPT-3.5 Turbo: In Italien wurden 334 Personen bei einer Razzia gegen die Mafia verhaftet. Die Mafia ist eine Gruppe von Kriminellen, die weltweit Verbrechen begehen. Die Polizei fand auch 15 Millionen Euro Bargeld. Eine Razzia ist eine geplante Durchsuchung durch die Polizei, um illegale Aktivitäten zu entlarven.

GPT-4: In Italien wurden 334 Menschen bei einer großen Polizeiaktion gegen die Mafia festgenommen. Die Mafia ist eine Gruppe von Verbrechern, die kriminelle Geschäfte machen. Die Polizei fand auch 15 Millionen Euro in bar. Eine Razzia ist eine geplante Durchsuchung der Polizei, um verbotene Dinge oder gesuchte Personen zu finden. Geldwäsche bedeutet, illegales Geld so zu verstecken, dass es wie legal verdientes Geld aussieht.

GPT-4o: 334 Menschen wurden bei einer Polizei-Aktion gegen die Mafia festgenommen. In Italien gibt es große Gruppen von Verbrechern. Diese Gruppen nennt man Mafia. Die Mafia macht kriminelle Geschäfte. Bei einer Polizei-Aktion gegen die Mafia wurden 334 Menschen in Italien, Deutschland, der Schweiz und Bulgarien festgenommen. Diese Menschen sollen Morde, Erpressungen und Geldwäsche gemacht haben. Die Polizei fand auch 15 Millionen Euro Bargeld.

Claude 3.5 Sonnet: 334 Personen wegen Verbrechen in Italien festgenommen. Rom In Italien gibt es große Verbrechergruppen, die zusammen als Mafia bekannt sind. Die Mafia ist gut organisiert und macht auf der ganzen Welt illegale Geschäfte. Bei einer großen Polizeiaktion wurden in Italien, Deutschland, der Schweiz und Bulgarien 334 Menschen festgenommen, die mit der Mafia zu tun haben sollen. Diese Menschen werden für Morde, Erpressungen und Geldwäsche verantwortlich gemacht. Die Polizei fand auch 15 Millionen Euro in bar. Erklärung: Razzia. Eine Razzia ist eine Durchsuchung durch die Polizei, wenn sie glaubt, dass in einem Gebäude illegale Dinge oder gesuchte Personen versteckt sind. Die Polizei plant Razzien genau, um sicherzustellen, dass niemand entkommt. Erklärung: Geldwäsche. Geldwäsche bedeutet, dass illegales Geld so versteckt wird, dass es legal aussieht.

Text 5

Original: Großer Brand im Hafen von Ancona. Ancona - In der Nacht auf Mittwoch ist im Hafen der italienischen Stadt Ancona ein großer Brand ausgebrochen. Zeugen berichteten von einigen Explosionen, verletzt wurde niemand. Durch den Brand entstand eine große schwarze Rauchwolke. Sie verbreitete sich über die ganze Stadt. Die Flammen zerstörten einige Lagerhallen und Fahrzeuge. Warum es gebrannt, weiß man noch. Das Feuer war am Mittwoch unter Kontrolle, aber die Lösch-Arbeiten dauerten am Nachmittag noch an. Die Menschen wurden aufgefordert, die Fenster geschlossen zu halten und nicht ins Freie zu gehen.

Reference: In einem Hafen in Italien gab es einen großen Brand. Ancona - Im Hafen der Stadt Ancona in Italien hat es in der Nacht auf Mittwoch einen großen Brand gegeben. Zeugen berichteten von Explosionen. Verletzt wurde niemand. Warum es gebrannt hat, weiß man noch nicht. Die Flammen zerstörten Lager-Hallen. Auch Fahrzeuge wurden zerstört. Durch den Brand entstand eine große schwarze Rauch-Wolke. Die Wolke verbreitete sich über die ganze Stadt. Das Feuer war bald unter Kontrolle. Die Lösch-Arbeiten dauerten aber am Nachmittag noch an. Die Menschen sollten nicht nach draußen gehen.

GPT-4: In Ancona, einer Stadt in Italien, gab es ein großes Feuer im Hafen. Niemand wurde verletzt, aber es gab eine große Rauchwolke. Die Menschen sollten drinnen bleiben, während die Feuerwehr das Feuer löschte.

Llama 3.1 405B: Feuer im Hafen von Ancona. Ancona - In der Nacht auf Mittwoch gab es ein großes Feuer im Hafen von Ancona, Italien. Es gab Explosionen, aber niemand wurde verletzt. Eine große Rauchwolke breitete sich über die Stadt aus. Einige Lagerhallen und Fahrzeuge brannten ab. Der Grund für das Feuer ist unklar. Am Mittwoch war das Feuer unter Kontrolle, aber die Löscharbeiten gingen weiter. Die Menschen sollen drinnen bleiben und die Fenster schließen.

Mistral 7B Instruct: Großer Brand im Hafen von Ancona. Ancona - In der Nacht zu Mittwoch brach im Hafen der italienischen Stadt Ancona ein großer Brand aus. Es gab einige Explosionen, aber niemand wurde verletzt. Eine große schwarze Rauchwolke breitete sich über die Stadt aus. Einige Lagerhallen und Fahrzeuge wurden zerstört. Der Grund für das Feuer ist noch unbekannt. Das Feuer war am Mittwoch unter Kontrolle, aber die Lösch-Arbeiten dauerten noch an. Menschen sollten Fenster geschlossen halten und nicht nach draußen gehen.

Gemini 2.5 Flash: Ein großer Brand brach im Hafen von Ancona aus, verursachte Explosionen, aber niemand wurde verletzt. Eine Rauchwolke breitete sich über die Stadt aus. Die Bewohner sollten Fenster geschlossen halten.

Text 6

Original: Sicherheits-Berater von US-Präsident Trump entlassen. Washington US-Präsident Donald Trump hat seinen Sicherheits-Berater John Bolton entlassen. Als Grund dafür gab Trump an, dass er mit den Vorschlägen von Bolton oft nicht einverstanden war. Bolton war immer für eine sehr harte Politik zum Beispiel gegen den Iran und Nordkorea. Bolton war nur eineinhalb Jahre lang der Sicherheits-Berater von Donald Trump. Der US-Präsident will in der kommenden Woche einen Nachfolger von John Bolton ernennen.

Reference: US-Präsident Trump entlässt seinen Sicherheits-Berater Bolton. Washington US-Präsident Donald Trump hat John Bolton entlassen. Bolton war der Sicherheits-Berater von Präsident Trump. Der Sicherheits-Berater berät den US-Präsident bei der Außenpolitik. Trump sagte, er war mit vielen Vorschlägen von Bolton nicht einverstanden. Deshalb hat er Bolton entlassen. Bolton war immer für eine harte Politik. Er wollte zum Beispiel noch mehr mit dem Iran und mit Nord-Korea streiten.

GPT-4: US-Präsident Trump hat seinen Sicherheitsberater John Bolton entlassen, weil er mit dessen Ideen oft nicht einverstanden war. Bolton wollte eine harte Politik gegen Länder wie Iran und Nordkorea. Er war nur eineinhalb Jahre im Amt. Trump will nächste Woche einen neuen Berater benennen.

GPT-4o: US-Präsident Trump hat seinen Sicherheits-Berater entlassen. Washington US-Präsident Donald Trump hat John Bolton entlassen. Trump sagt, er war oft nicht einverstanden mit den Ideen von Bolton. Bolton wollte eine sehr strenge Politik gegen Länder wie Iran und Nordkorea. Bolton war nur eineinhalb Jahre der Sicherheits-Berater von Trump. Trump will nächste Woche einen neuen Berater bestimmen.

Deepseek v3: US-Präsident Trump entlässt Sicherheitsberater. Washington – Präsident Donald Trump hat John Bolton als Sicherheitsberater entlassen, da er oft mit dessen Vorschlägen nicht übereinstimmte. Bolton, der eine harte Politik gegenüber Iran und Nordkorea bevorzugte, war anderthalb Jahre im Amt. Trump will nächste Woche einen Nachfolger benennen.

Gemini 2.5 Flash: US-Präsident Trump hat seinen Sicherheitsberater John Bolton entlassen, weil er oft anderer Meinung als Bolton war. Bolton wollte eine harte Politik gegen Länder wie Iran und Nordkorea. Er war eineinhalb Jahre im Amt. Trump sucht jetzt einen Nachfolger.

Text 7

Original: Viele Fußgänger-Unfälle auf Zebrastreifen. Wien Im Jahr 2019 sind auf den Zebrastreifen in Österreich viele Unfälle geschehen. So wurden 12 Fußgänger getötet und 1.225 Fußgänger verletzt. Dabei sollten Zebrastreifen doch Fußgängern ermöglichen, sicher über die Straße zu gehen. Der Verkehrsclub Österreich kennt einige Ursachen für diese vielen Unfälle. So fahren Autos viel zu schnell. Laut Gesetz dürfen sich die Autos einem Zebrastreifen aber nur so nähern, dass sie jederzeit abbremsen können. Je näher sie dem Zebrastreifen kommen, desto langsamer sollten sie also fahren. Das machen aber nicht alle Autofahrer. Auch parken Autos oft viel zu nah am Zebrastreifen. Weil die parkenden Autos den Zebrastreifen verdecken, sehen andere Autofahrer die Menschen am Zebrastreifen oft sehr spät. Vom Gesetz her dürfen Autos 5 Meter vor dem Zebrastreifen nicht parken. Der Verkehrsclub Österreich fordert, dass sie 10 Meter vor dem Zebrastreifen nicht parken dürfen.

Reference: Viele Unfälle auf Zebrastreifen in Österreich. Wien Zebrastreifen sind dazu da, dass Fußgänger sicher über die Straße gehen können. Dennoch passieren in Österreich auf Zebrastreifen viele Unfälle. Im Jahr 2019 sind 12 Fußgänger auf Zebrastreifen getötet worden. 1.225 Fußgänger wurden verletzt. Der Verkehrsclub Österreich kennt einige Gründe für die Unfälle. Autos fahren zum Beispiel schneller als erlaubt. Sie können dann auch nicht rechtzeitig abbremsen. Auch parken die Autos oft viel zu nah bei dem Zebrastreifen. Dadurch verdecken die Autos teilweise die Sicht auf den Zebrastreifen.

GPT-3.5 Turbo: Viele Fußgängerunfälle an Zebrastreifen. In Wien gab es 2019 viele Unfälle an Zebrastreifen in Österreich. Zwölf Fußgänger starben und 1.225 wurden verletzt. Zebrastreifen sollen Fußgängern helfen, die Straße sicher zu überqueren. Der Österreichische Verkehrsclub kennt einige Gründe für diese Unfälle. Autos fahren zu schnell und sollten sich Fußgängerüberwegen langsam nähern, um bei Bedarf anzuhalten. Aber nicht alle Autofahrer tun dies. Außerdem parken Autos zu nah an Fußgängerüberwegen und versperren anderen Autofahrern die Sicht. Laut Gesetz sollten Autos nicht näher als 5 Meter an einem Fußgängerüberweg parken. Der Verkehrsclub möchte, dass diese Regel auf 10 Meter geändert wird.

Claude 3.5 Haiku: Viele Unfälle auf Zebrastreifen in Österreich. Wien - Im Jahr 2019 gab es viele Unfälle auf Zebrastreifen in Österreich. Dabei starben 12 Fußgänger und 1.225 wurden verletzt. Zebrastreifen sollen Fußgängern helfen, sicher über die Straße zu gehen, aber oft fahren Autos zu schnell. Autos müssen so fahren, dass sie vor einem Zebrastreifen leicht bremsen können, aber das tun nicht alle Fahrer. Auch parken Autos oft zu nah am Zebrastreifen, sodass andere Fahrer Fußgänger nicht rechtzeitig sehen. Der Verkehrsclub Österreich will, dass Autos 10 Meter vor einem Zebrastreifen nicht parken dürfen, statt wie bisher 5 Meter.

Llama 3.1 405B: Viele Unfälle auf Zebrastreifen in Österreich. Wien - 2019 gab es viele Unfälle auf Zebrastreifen in Österreich. 12 Fußgänger starben und 1.225 wurden verletzt. Zebrastreifen sollen Fußgängern helfen, sicher über die Straße zu kommen. Der Verkehrsclub Österreich meint, dass Autos oft zu schnell fahren und zu nah am Zebrastreifen parken. Autos sollten langsamer fahren und nicht so nah parken, damit andere Autofahrer Fußgänger besser sehen können.

Mistral 7B Instruct: Viele Unfälle auf Zebrastreifen in Österreich. Wien Im Jahr 2019 gab es viele Unfälle auf Zebrastreifen in Österreich. 12 Fußgänger starben und 1.225 wurden verletzt. Eigentlich sollen Zebrastreifen den Fußgängern helfen, sicher über die Straße zu gehen. Der Verkehrsclub Österreich meint, dass viele Autos zu schnell fahren. Autos müssen sich langsam einem Zebrastreifen nähern, damit sie jederzeit bremsen können. Auch parken viele Autos zu nah am Zebrastreifen, sodass andere Fahrer Fußgänger oft zu spät sehen. Der Verkehrsclub fordert, dass Autos 10 Meter vor einem Zebrastreifen nicht parken dürfen.

Text 8

Original: Die Österreicher gehen oft zu Fuß. 2 Drittel der Österreicher gehen oft zu Fuß. Das hat eine Umfrage ergeben. Vor allem in den Städten gehen viele zu Fuß zum Einkaufen oder zur Arbeit. In Wien sind es sogar 78 Prozent, die das tun. In kleineren Orten gehen nur 58 Prozent der Befragten oft zu Fuß. Das liegt zum Beispiel daran, dass viele Geschäfte nicht in den Orten sondern weit außerhalb liegen. In großen Städten gibt es viel mehr Geschäfte, die man leicht zu Fuß erreichen kann. Zu Fuß gehen hat viele Vorteile. Es ist gesund, umweltfreundlich und gratis.

Reference: Viele Menschen in Österreich gehen oft zu Fuß. Wien - Zwei Drittel von den Menschen in Österreich gehen oft zu Fuß. Das hat eine Umfrage ergeben. Besonders in den großen Städten gehen die Menschen oft zu Fuß. Denn dort gibt es viele Geschäfte, die nahe bei einander sind. In kleineren Orten gehen weniger Menschen oft zu Fuß. Denn dort gibt es weniger Geschäfte. Viele Geschäfte sind weit außerhalb von den Orten. Da muss man zum Einkaufen mit dem Auto hinfahren. Zu Fuß gehen ist gut für die Menschen. Denn es ist gesund und kostet nichts. Außerdem ist es gut für die Umwelt.

GPT-3.5 Turbo: Österreicher gehen oft zu Fuß. Laut einer Umfrage gehen zwei Drittel der Österreicher oft zu Fuß. Viele gehen zu Fuß zum Einkaufen oder zur Arbeit, vor allem in Städten. In Wien sind es 78 %. In kleineren Städten gehen nur 58 % oft zu Fuß, weil die Geschäfte weit entfernt sind. In großen Städten sind viele Geschäfte leicht zu Fuß zu erreichen. Zu Fuß gehen ist gesund, umweltfreundlich und kostenlos.

GPT-4o: Viele Österreicher gehen oft zu Fuß. Eine Umfrage hat das gezeigt. Vor allem in den Städten gehen viele zu Fuß einkaufen oder zur Arbeit. In Wien sind es 78 Prozent. In kleinen Orten sind es nur 58 Prozent. Das liegt daran, dass Geschäfte oft weg sind. In großen Städten sind die Geschäfte nah. Zu Fuß gehen hat viele Vorteile. Es ist gesund, gut für die Umwelt und kostet nichts.

Llama 3.1 405B: Die meisten Österreicher gehen oft zu Fuß. Zwei Drittel der Österreicher gehen regelmäßig zu Fuß, vor allem in Städten. In Wien sind es sogar 78 Prozent. In kleineren Orten sind es 58 Prozent, da viele Geschäfte außerhalb liegen. Zu Fuß gehen ist gesund, umweltfreundlich und kostenlos.

Deepseek v3: Zwei Drittel der Österreicher gehen häufig zu Fuß, besonders in Städten wie Wien, wo es 78 Prozent sind. In kleineren Orten sind es 58 Prozent. Zu Fuß gehen ist gesund und umweltfreundlich.

Text 9

Original: Formel-1-Rennen in Monaco abgesagt. London - Das Rennen der Formel 1 in Monaco ist wegen der Corona-Krise abgesagt worden. Eigentlich sollte es am 24. Mai stattfinden. Damit wird zum ersten Mal seit dem Jahr 1954 nicht in Monaco gefahren. Das Rennen zählt zur Weltmeisterschaft der Formel 1. Außerdem wurden die Rennen in den Niederlanden und Barcelona in Spanien verschoben. Sie sollten eigentlich im Mai gefahren werden. Das erste Rennen der neuen Saison soll am 7. Juni in Aserbaidschan stattfinden. Erklärung: Formel 1. In der Formel 1 fahren die besten Rennfahrer aus der ganzen Welt mit sehr schnellen Autos. Zur Formel 1 gehören verschiedene Auto-Rennen. Alle Rennen der Formel 1 zählen zur Weltmeisterschaft.

Reference: Das Formel-1-Rennen in Monaco findet heuer nicht statt. London - Im Land Monaco findet heuer kein Formel-1-Rennen statt. Es wurde wegen dem Corona-Virus abgesagt. Es ist das erste Mal seit 66 Jahren, dass das Rennen in Monaco abgesagt wurde. Die Formel-1-Rennen in den Niederlanden und in Spanien wurden nur verschoben. Sie sollen später nachgeholt werden. Das erste Rennen heuer soll nun am 7. Juni im Land Aserbaidschan starten. Erklärung: Formel 1. In der Formel 1 fahren die besten Fahrer mit sehr schnellen Renn-Autos. Zur Formel 1 gehören verschiedene Rennen. Alle Rennen zählen zur Welt-Meisterschaft. In jedem Rennen bekommen die besten Fahrer Punkte. Diese Punkte werden zusammengezählt. Weltmeister wird der Fahrer mit den meisten Punkten.

GPT-3.5 Turbo: Das Formel-1-Rennen in Monaco wurde wegen der Corona-Krise abgesagt. Es sollte am 24. Mai stattfinden. Auch Rennen in den Niederlanden und Spanien wurden verschoben. Das erste Rennen soll jetzt am 7. Juni in Aserbaidschan stattfinden.

Claude 3.5 Sonnet: Formel-1-Rennen in Monaco abgesagt. London - Wegen der Corona-Krise findet das Formel-1-Rennen in Monaco nicht statt. Es sollte am 24. Mai stattfinden. Seit 1954 gab es dort jedes Jahr ein Rennen. Auch die Rennen in den Niederlanden und Spanien werden verschoben. Das erste Rennen der Saison soll am 7. Juni in Aserbaidschan stattfinden. Erklärung: Formel 1. Die Formel 1 ist eine Rennserie mit den besten Fahrern der Welt. Die Rennen zählen zur Weltmeisterschaft.

Llama 3.1 405B: Formel-1-Rennen in Monaco abgesagt. London - Wegen der Corona-Krise wurde das Formel-1-Rennen in Monaco abgesagt. Es sollte am 24. Mai stattfinden. Seit 1954 wurde das Rennen immer gefahren. Auch die Rennen in den Niederlanden und Barcelona wurden verschoben. Das erste Rennen der Saison soll am 7. Juni in Aserbaidschan sein. Erklärung: Formel 1. Formel 1 ist eine Rennsportart, bei der die besten Fahrer der Welt in schnellen Autos fahren. Alle Rennen zählen zur Weltmeisterschaft.

Mistral 7B Instruct: Formel-1-Rennen in Monaco abgesagt. London - Wegen der Corona-Krise wurde das Formel-1-Rennen in Monaco abgesagt. Es sollte am 24. Mai stattfinden. Zum ersten Mal seit 1954 wird dort nicht gefahren. Auch die Rennen in den Niederlanden und Spanien wurden verschoben. Das erste Rennen der neuen Saison soll am 7. Juni in Aserbaidschan stattfinden. Erklärung: Formel 1. Die Formel 1 ist eine Renn-Serie, bei der die besten Rennfahrer der Welt mit sehr schnellen Autos gegeneinander antreten. Die Rennen zählen zur Weltmeisterschaft der Formel 1.

H Readability Survey – LLM Performance on Individual Texts

Model	Score
Original	3,52
Reference	3,08
Claude 3.5 Haiku	4,36
Claude 3.5 Sonnet	3,64
Mistral 7B Instruct	3,84
Gemini 2.5 Flash	4,68

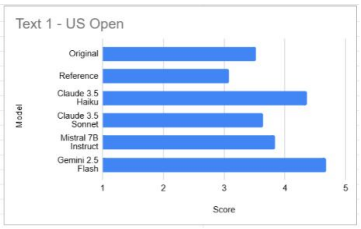


Figure 6: Readability scores of the LLMs for Text 1

Model	Score
Original	3,12
Reference	3,48
Claude 3.5 Haiku	3,56
Claude 3.5 Sonnet	3,44
Deepseek v3	4,80
Gemini 2.5 Flash	4,68

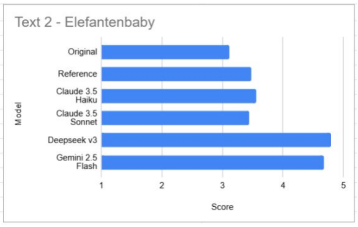


Figure 7: Readability scores of the LLMs for Text 2

Model	Score
Original	2,76
Reference	3,48
GPT-3.5 Turbo	4,36
GPT-4	4,08
GPT-4o	4,04
Claude 3.5 Sonnet	3,24

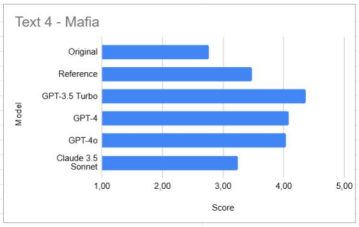


Figure 8: Readability scores of the LLMs for Text 4

Model	Score
Original	3,32
Reference	3,48
GPT-4	4,84
Llama 3.1 405B	3,88
Mistral 7B Instruct	3,72
Gemini 2.5 Flash	4,24

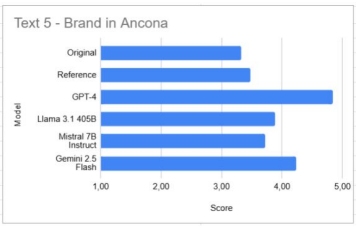


Figure 9: Readability scores of the LLMs for Text 5

Model	Score
Original	2,64
Reference	3,48
GPT-3.5 Turbo	3,20
Claude 3.5 Haiku	3,52
Llama 3.1 405B	4,16
Mistral 7B Instruct	3,80

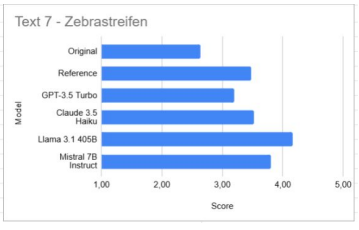


Figure 10: Readability scores of the LLMs for Text 7

Model	Score
Original	3,16
Reference	3,16
GPT-3.5 Turbo	3,68
GPT-4o	3,92
Llama 3.1 405B	4,48
Deepseek v3	4,36

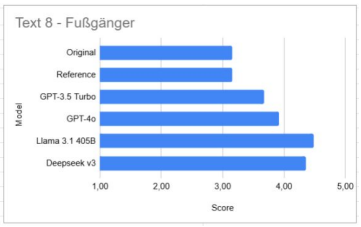


Figure 11: Readability scores of the LLMs for Text 8

Model	Score
Original	3,44
Reference	2,80
GPT-3.5 Turbo	4,88
Claude 3.5 Sonnet	3,84
Llama 3.1 405B	3,88
Mistral 7B Instruct	3,60

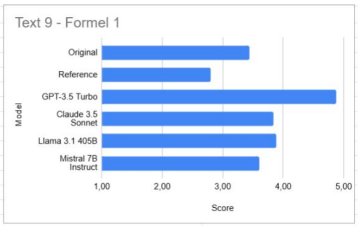


Figure 12: Readability scores of the LLMs for Text 9